

CNFSDP

Centre National de Formation en Statistique,
Démographie et Planification
Brazzaville, République du Congo

Introduction au Machine Learning

Chapitre 1 – Fondements du machine learning

Prédire, mesurer l'erreur, éviter le sur-apprentissage

Rois Céti DIMBAMBA
Ingénieur statisticien économiste · Actuaire · CV en ligne

Licence 3 · Semestre 5 · UE Informatique IV
Année académique 2026-2027 · 14 octobre 2026

Plan et objectifs

1. Qu'est-ce que le machine learning ?
2. Formaliser la prédiction
3. Le meilleur prédicteur possible
4. Sur-apprentissage
5. Évaluer et choisir un modèle
6. Mesurer la performance
7. En Python
8. TP en salle

Objectifs de la séance

- Savoir ce qu'est un problème d'apprentissage et en connaître le vocabulaire.
- Définir l'erreur d'un modèle : perte, risque, risque empirique.
- Connaître le meilleur prédicteur possible et l'erreur irréductible.
- Comprendre le sur-apprentissage et la bonne façon d'évaluer un modèle.
- Lire les métriques usuelles : RMSE, précision, rappel, AUC.

Prérequis : chapitre 0 (espérance, variance, probabilité conditionnelle).

1

Qu'est-ce que le machine learning ?

Apprendre à partir d'exemples

Définition 1.1 (Machine learning, ou apprentissage automatique). Ensemble de méthodes qui construisent *automatiquement*, à partir d'exemples observés, une règle permettant de prédire ou de résumer des données nouvelles.

Programmation classique

On écrit la règle à la main : « si la mère a fait le secondaire et vit en ville, alors l'enfant est vacciné ».

Machine learning

On fournit des milliers d'exemples (enfants, caractéristiques, vacciné ou non) ; l'algorithme *apprend* la règle.

Exemple. Prédire le revenu d'un ménage, la vaccination complète d'un enfant, le défaut de remboursement d'un emprunteur ; regrouper des ménages qui se ressemblent.

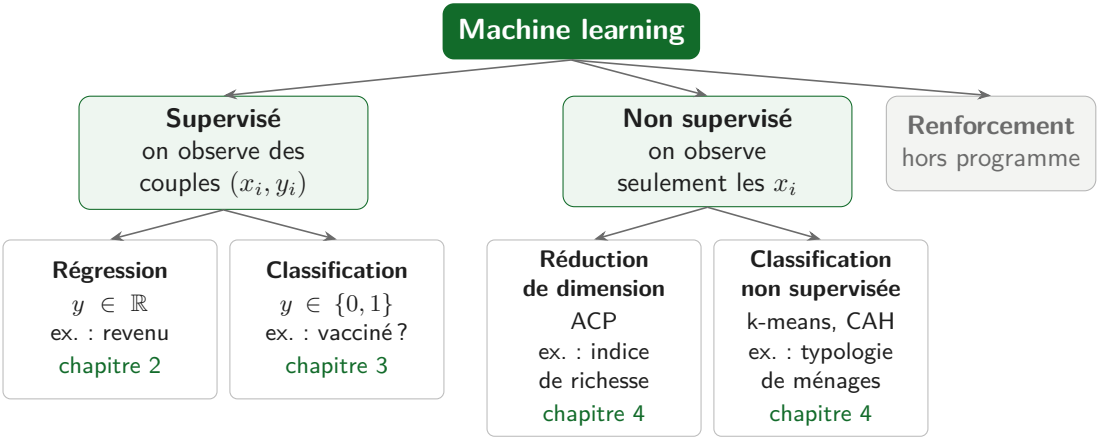
Le tableau de données

	variables explicatives x			cible y
enfant	âge mère	éducation	milieu	vacciné
1	24	primaire	rural	0
2	31	secondaire	urbain	1
3	19	aucune	rural	0
4	28	secondaire	rural	1
⋮	⋮	⋮	⋮	⋮

- Une **ligne** $=$ un individu $i = 1, \ldots, n$.
- Les **variables explicatives** de l'individu i forment un vecteur $x_i \in \mathbb{R}^d$.
- La **variable cible** y_i est ce que l'on veut prédire.
- Les x_i forment une matrice X à n lignes et d colonnes.

Les variables qualitatives (éducation, milieu) sont codées en nombres avant l'apprentissage (chapitre 5).

Les grandes familles de problèmes



Ce chapitre pose le cadre du supervisé ; le non supervisé a son propre cadre au chapitre 4.

2

Formaliser la prédiction

Données et prédicteur

Définition 1.2 (Données). On note X le vecteur des variables explicatives et Y la variable cible d'un individu tiré au hasard dans la population : (X, Y) est un couple *aléatoire*, dont la loi est *inconnue*. On dispose d'un *échantillon d'apprentissage* $\mathcal{D}_n = \{(x_1, y_1), \ldots, (x_n, y_n)\}$: n réalisations indépendantes de (X, Y).

Définition 1.3 (Prédicteur). Un *prédicteur* est une fonction f qui, à des caractéristiques x, associe une prédiction $f(x)$ de y. Un *algorithme d'apprentissage* fabrique un prédicteur $\hat{f}$ à partir de l'échantillon $\mathcal{D}_n$.

Remarque. Le prédicteur appris dépend de l'échantillon : avec une autre enquête, on obtiendrait un $\hat{f}$ un peu différent.

Mesurer une erreur : la fonction de perte

Définition 1.4 (Perte). Une *perte* est une fonction $\ell(\hat{y}, y) \geq 0$ qui mesure le coût de prédire $\hat{y}$ quand la vraie valeur est y.

Perte	Formule	Usage	Exemple
quadratique	$\ell(\hat{y}, y) = (\hat{y} - y)^2$	régression	prédit 3, vrai 5 : perte 4
absolue	$\ell(\hat{y}, y) = \lvert\hat{y} - y\rvert$	régression	prédit 3, vrai 5 : perte 2
0-1	$\ell(\hat{y}, y) = \begin{cases} 1 & \text{si } \hat{y} \neq y \\ 0 & \text{sinon} \end{cases}$	classification	prédit 1, vrai 0 : perte 1

La perte quadratique pénalise fortement les grosses erreurs ; la perte absolue est moins sensible aux valeurs extrêmes.

Risque et risque empirique

Définition 1.5 (Risque, risque empirique). Le *risque* d'un prédicteur f est son erreur moyenne sur toute la population :

$$R(f) = \mathbb{E}\big[\ell\big(f(X), Y\big)\big].$$

Son *risque empirique* est son erreur moyenne sur l'échantillon :

$$\widehat{R}_n(f) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(f(x_i), y_i\big).$$

- En classification avec la perte 0-1, $R(f) = \mathbb{P}\big(f(X) \neq Y\big)$: la *probabilité d'erreur*.
- Le risque est l'objectif, mais il est inconnu (la loi de (X, Y) l'est) ; le risque empirique, lui, se calcule.
- Si f est fixé à l'avance, la loi des grands nombres donne $\widehat{R}_n(f) \approx R(f)$ pour n grand.

Un calcul de risque empirique

On veut prédire le nombre d'enfants y d'une femme selon son milieu x (urbain, rural), sur $n = 10$ femmes : urbain : $2, 3, 2, 3$; rural : $4, 5, 3, 6, 5, 4$.

Prédicteur constant $f_0(x) = \bar{y} = 3{,}7$:

$$\widehat{R}_n(f_0) = \tfrac{1}{10} \textstyle\sum_i (y_i - 3{,}7)^2 = 1{,}61.$$

Prédicteur par milieu : moyenne de chaque groupe, $f_1(\text{urbain}) = 2{,}5$, $f_1(\text{rural}) = 4{,}5$:

$$\widehat{R}_n(f_1) = \tfrac{1}{10}\,(1 + 5{,}5) = 0{,}65.$$

Lecture. Utiliser l'information x divise l'erreur quadratique moyenne par plus de deux. Le prédicteur f_1 prédit, dans chaque groupe, la moyenne du groupe : c'est exactement le meilleur prédicteur de la section suivante.

3

Le meilleur prédicteur possible

La meilleure constante est la moyenne

Proposition 1.6

Soit Z une variable aléatoire de variance finie. Pour tout réel c,

$$\mathbb{E}\big[(Z-c)^2\big] = \mathrm{Var}(Z) + \big(\mathbb{E}[Z]-c\big)^2.$$

La fonction $c \mapsto \mathbb{E}\big[(Z-c)^2\big]$ atteint donc son minimum en $c = \mathbb{E}[Z]$, et la valeur minimale est $\mathrm{Var}(Z)$.

Preuve. On écrit $Z - c = (Z - \mathbb{E}Z) + (\mathbb{E}Z - c)$ et l'on développe le carré : $\mathbb{E}[(Z-c)^2] = \mathbb{E}[(Z-\mathbb{E}Z)^2] + 2(\mathbb{E}Z-c)\,\mathbb{E}[Z-\mathbb{E}Z] + (\mathbb{E}Z-c)^2$. Le terme du milieu est nul car $\mathbb{E}[Z-\mathbb{E}Z] = 0$. □

Lecture. Si l'on doit résumer une variable par un seul nombre et que l'on paie le carré de l'erreur, il faut choisir sa moyenne ; l'erreur restante est sa variance.

Régression : le meilleur prédicteur est la moyenne conditionnelle

Théorème 1.7 (Prédicteur de Bayes en régression)

En perte quadratique, le prédicteur qui a le plus petit risque est

$$f^*(x) = \mathbb{E}[Y \mid X = x],$$

la moyenne de Y parmi les individus ayant les caractéristiques x. On l'appelle *prédicteur de Bayes*.

Preuve (idée). Pour chaque valeur x, on doit choisir un nombre $f(x)$ qui prédit Y dans le groupe des individus tels que $X = x$. La proposition précédente, appliquée à la loi de Y dans ce groupe, dit que le meilleur choix est la moyenne du groupe, $\mathbb{E}[Y \mid X = x]$. □

Remarque. En perte absolue, le même raisonnement donne la *médiane* de Y dans chaque groupe (admis) : plus robuste pour des revenus très dispersés.

L'erreur irréductible

Définition 1.8 (Risque de Bayes, excès de risque). Le *risque de Bayes* $R^* = R(f^*)$ est le plus petit risque possible. L'*excès de risque* d'un prédicteur f est $R(f) - R^* \geq 0$.

Exemple. [Modèle signal + bruit] Si $Y = g(X) + \varepsilon$, où le bruit ε est indépendant de X, de moyenne 0 et de variance σ^2, alors

$$f^*(x) = g(x) \qquad \text{et} \qquad R^* = \sigma^2.$$

Même en connaissant parfaitement g, on se trompe en moyenne de σ^2 : c'est le bruit, que les variables X n'expliquent pas.

À retenir

Aucun algorithme ne fait mieux que R^*. On juge un modèle à la distance entre son risque et R^*.

Classification : le classifieur de Bayes

Ici $y \in \{0, 1\}$, perte 0-1, et l'on note $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ la probabilité d'être dans la classe 1 sachant x.

Théorème 1.9 (Classifieur de Bayes)

Le classifieur qui a la plus petite probabilité d'erreur est

$$f^*(x) = \begin{cases} 1 & \text{si } \eta(x) > \frac{1}{2}, \\ 0 & \text{sinon,} \end{cases} \qquad \text{et} \qquad R^* = \mathbb{E}\big[\min\{\eta(X), 1 - \eta(X)\}\big].$$

Preuve. Pour un individu de caractéristiques x, prédire 1 est faux avec probabilité $1 - \eta(x)$, prédire 0 est faux avec probabilité $\eta(x)$. La meilleure décision choisit la plus petite des deux, soit $\min\{\eta(x), 1 - \eta(x)\}$; on fait la moyenne sur X. □

En clair : on prédit la classe la plus probable sachant ce que l'on observe.

Un exemple chiffré

$Y = 1$ si l'enfant est complètement vacciné, $X =$ niveau d'éducation de la mère (chiffres fictifs).

x	aucune	primaire	secondaire ou plus
$\mathbb{P}(X = x)$	$0{,}3$	$0{,}4$	$0{,}3$
$\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$	$0{,}45$	$0{,}60$	$0{,}80$
$f^*(x)$	0	1	1
erreur $\min\{\eta(x), 1 - \eta(x)\}$	$0{,}45$	$0{,}40$	$0{,}20$

$$R^* = 0{,}3 \times 0{,}45 + 0{,}4 \times 0{,}40 + 0{,}3 \times 0{,}20 = 0{,}355.$$

Lecture. Avec la seule éducation de la mère, aucun modèle ne peut se tromper moins de $35{,}5\,\%$ du temps. Pour faire mieux, il faut d'autres variables.

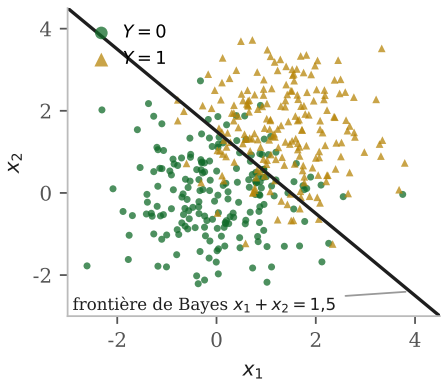
Un exemple continu : deux nuages gaussiens

Deux classes équiprobables ; sachant $Y = 0$, $X \sim \mathcal{N}\big((0,0), I_2\big)$; sachant $Y = 1$, $X \sim \mathcal{N}\big((1{,}5;1{,}5), I_2\big)$.

Proposition 1.10 (admise)

Le classifieur de Bayes prédit 1 si et seulement si $x_1 + x_2 > 1{,}5$: la frontière est une *droite*. Son erreur vaut $R^* = \Phi(-1{,}06) \approx 0{,}144$, où Φ est la fonction de répartition de $\mathcal{N}(0,1)$.

Lecture. Les nuages se recouvrent : environ $14\,\%$ d'erreurs sont inévitables. Nous comparerons nos modèles à ce plancher.



Quand les erreurs n'ont pas le même coût

En dépistage, manquer un malade (faux négatif) est plus grave qu'une fausse alerte (faux positif).

Si un faux négatif coûte c_{FN} et un faux positif c_{FP}, la règle optimale devient

$$f^*(x) = 1 \iff \eta(x) > t^* = \frac{c_{\mathrm{FP}}}{c_{\mathrm{FP}} + c_{\mathrm{FN}}}.$$

Le seuil $\frac{1}{2}$ n'est que le cas de coûts égaux.

Exemple. Si manquer un malade coûte 9 fois plus qu'une fausse alerte : $t^* = \frac{1}{1+9} = 0{,}1$. On déclare positif dès que la probabilité dépasse $10\,\%$.

4

Sur-apprentissage

Apprendre, c'est minimiser l'erreur sur l'échantillon

Définition 1.11 (Minimisation du risque empirique). On choisit une famille de prédicteurs $\mathcal{F}$, puis on retient le prédicteur de $\mathcal{F}$ qui fait le moins d'erreurs sur l'échantillon :

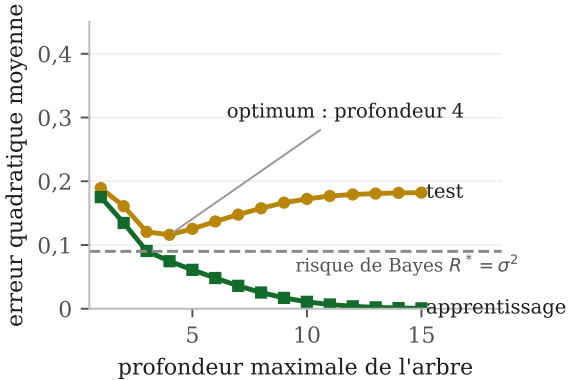
$$\hat{f} \in \arg\min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

Exemples de familles : droites ou plans (régression linéaire, chapitre 2) ; arbres de décision de profondeur au plus p (chapitre 3).

Famille trop pauvre. Elle ne contient pas de bon prédicteur : on se trompe même sur l'échantillon (*sous-apprentissage*).

Famille trop riche. Elle contient un prédicteur qui colle à chaque point, bruit compris (*sur-apprentissage*).

Le sur-apprentissage en image



$Y = \sin(2\pi X) + \varepsilon$, $\sigma = 0{,}3$, $n = 200$; arbres de profondeur 1 à 15.

- L'erreur d'apprentissage tend vers 0 : l'arbre profond *apprend par cœur*, bruit compris.
- L'erreur test baisse, puis remonte.
- Le meilleur arbre (profondeur 4) reste au-dessus du plancher $R^* = \sigma^2 = 0{,}09$.

Biais et variance

En perte quadratique, l'erreur moyenne d'un prédicteur appris se décompose (admis) :

$$\text{erreur test moyenne} = \underbrace{R^*}_{\text{bruit}} + \underbrace{\text{biais}^2}_{\text{modèle trop rigide}} + \underbrace{\text{variance}}_{\text{modèle trop instable}} .$$

	Modèle trop simple	**Modèle trop complexe**
Biais	élevé	faible
Variance	faible	élevée
Erreur d'apprentissage	élevée	presque nulle
Diagnostic	sous-apprentissage	sur-apprentissage

À retenir

L'erreur sur les données d'apprentissage est trop optimiste : on n'évalue jamais un modèle sur les données qui ont servi à le construire.

5

Évaluer et choisir un modèle

Évaluer sur un échantillon test

Définition 1.12 (Échantillon test, risque test). Un *échantillon test* est un ensemble de m individus *non utilisés* pour l'apprentissage. Le *risque test* de $\hat{f}$ est

$$\widehat{R}_{\text{test}}(\hat{f}) = \frac{1}{m}\sum_{j=1}^{m} \ell\big(\hat{f}(x'_j), y'_j\big).$$

Comme $\hat{f}$ n'a pas vu ces individus, $\widehat{R}_{\text{test}}$ estime honnêtement le vrai risque.

Proposition 1.13 (Intervalle de confiance d'un taux d'erreur)

En classification, si $\hat{p} = \widehat{R}_{\text{test}}(\hat{f})$ est le taux d'erreur sur m individus test, un intervalle de confiance approché à $95\,\%$ pour le vrai taux d'erreur est $\hat{p} \pm 1{,}96\sqrt{\hat{p}(1-\hat{p})/m}$ (chapitre 0, théorème central limite).

Exemple : $\hat{p} = 15\,\%$ sur $m = 1\,000$ individus donne $15\,\% \pm 2{,}2$ points.

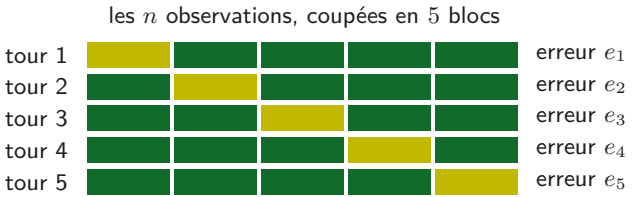
Apprentissage, validation, test

apprentissage (60 %)	validation (20 %)	test (20 %)
on ajuste chaque modèle candidat	on choisit le meilleur	on mesure, une seule fois

1. On met de côté un échantillon **test**, que l'on ne regarde plus jusqu'à la fin.
2. On ajuste plusieurs modèles sur l'**apprentissage** et on les compare sur la **validation**.
3. On réentraîne le modèle choisi, puis on l'évalue **une seule fois** sur le test.

Fuite d'information. Choisir un modèle d'après son score test rend ce score optimiste, comme l'erreur d'apprentissage.

Validation croisée



Définition 1.14 (Validation croisée à V blocs). On coupe l'échantillon en V blocs. À chaque tour, on apprend sur $V-1$ blocs (vert) et l'on mesure l'erreur e_v sur le bloc restant (jaune). Le score de validation croisée est la moyenne $\frac{1}{V}\sum_{v=1}^{V} e_v$.

Chaque observation sert une fois à valider : utile quand les données sont peu nombreuses. En pratique $V = 5$ ou 10.

6

Mesurer la performance

Métriques de régression

Sur m individus test, avec $\hat{y}_j$ la prédiction et y_j la vraie valeur :

Métrique	Formule	Lecture
EQM (MSE)	$\frac{1}{m}\sum_j (\hat{y}_j - y_j)^2$	erreur quadratique moyenne
RMSE	$\sqrt{\text{EQM}}$	même unité que y : « on se trompe d'environ…»
MAE	$\frac{1}{m}\sum_j \lvert\hat{y}_j - y_j\rvert$	erreur absolue moyenne, robuste aux valeurs extrêmes

Exemple. Une RMSE de $0{,}9$ enfant signifie qu'on se trompe typiquement d'un peu moins d'un enfant sur le nombre d'enfants d'une femme.

Classification : la matrice de confusion

	prédit 1	**prédit 0**
vrai 1	**VP $= 116$**	FN $= 26$
vrai 0	FP $= 18$	**VN $= 140$**

VP : vrais positifs ; FN : faux négatifs ; FP : faux positifs ; VN : vrais négatifs ; $m = 300$ individus test.

- **Exactitude** : $\frac{\mathrm{VP}+\mathrm{VN}}{m} = \frac{256}{300} = 0{,}853.$
- **Précision** : parmi les prédits positifs, part de vrais positifs, $\frac{\mathrm{VP}}{\mathrm{VP}+\mathrm{FP}} = 0{,}866.$
- **Rappel** : parmi les vrais positifs, part détectée, $\frac{\mathrm{VP}}{\mathrm{VP}+\mathrm{FN}} = 0{,}817.$
- **F1** : $\frac{2\times\text{précision}\times\text{rappel}}{\text{précision}+\text{rappel}} = 0{,}841.$

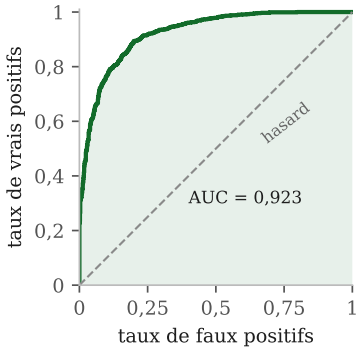
Classes déséquilibrées. Si $5\,\%$ des enfants sont émaciés, prédire « personne n'est émacié » donne $95\,\%$ d'exactitude… et un rappel nul.

Scores, courbe ROC et AUC

Beaucoup de modèles donnent un *score* $s(x)$, par exemple une estimation de $\eta(x)$, puis classent en 1 si $s(x) > t$.

Définition 1.15 (Courbe ROC, AUC). Quand le seuil t varie, on trace le taux de vrais positifs (rappel) en fonction du taux de faux positifs ($1-$ spécificité) : c'est la *courbe ROC*. L'*AUC* est l'aire sous cette courbe.

Interprétation (admise) : l'AUC est la probabilité qu'un positif tiré au hasard ait un score plus élevé qu'un négatif tiré au hasard. $0{,}5$ = hasard, 1 = classement parfait.



L'outil : scikit-learn

Instruction	Rôle
`f.fit(X, y)`	apprend le prédicteur $\hat{f}$ sur l'échantillon
`f.predict(X)`	calcule les prédictions $\hat{f}(x)$
`f.predict_proba(X)[:, 1]`	donne le score $s(x)$, estimation de $\eta(x)$
`train_test_split`	sépare apprentissage et test
`cross_val_score`	validation croisée
`GridSearchCV`	choix des réglages par validation croisée
`sklearn.metrics`	EQM, matrice de confusion, AUC…

Tous les modèles du cours partagent cette interface : changer de modèle revient à changer une ligne.

7

En Python

Comparer des modèles au classifieur de Bayes

```python
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
rng = np.random.default_rng(0)

def simuler(n):                                  # deux nuages gaussiens
    y = rng.integers(0, 2, n)
    return rng.standard_normal((n, 2)) + 1.5 * y[:, None], y

X, y = simuler(1_000); Xt, yt = simuler(10_000)   # apprentissage, test
m = len(yt)
for nom, f in [("logistique", LogisticRegression()),
               ("arbre profond", DecisionTreeClassifier(random_state=0))]:
    err = np.mean(f.fit(X, y).predict(Xt) != yt)  # taux d'erreur test
    print(nom, round(err, 4), "±", round(1.96 * np.sqrt(err * (1 - err) / m), 4))
print("Bayes", np.mean((Xt.sum(axis=1) > 1.5) != yt))
# logistique 0.1476 ± 0.007 | arbre profond 0.2049 ± 0.0079 | Bayes 0.1445
```

La logistique est presque au plancher de Bayes ; l'arbre profond sur-apprend.

Validation croisée, matrice de confusion, AUC

```
from sklearn.model_selection import cross_val_score
from sklearn.metrics import roc_auc_score, confusion_matrix
y = rng.integers(0, 2, 1_000)
X = rng.standard_normal((1_000, 2)) + 1.5 * y[:, None]

f = LogisticRegression()
print(cross_val_score(f, X, y, cv=5).round(3))  # [0.82 0.88 0.895 0.835 0.87]

f.fit(X[:700], y[:700])                         # 700 pour apprendre, 300 pour tester
s, yt = f.predict_proba(X[700:])[:, 1], y[700:]
print(confusion_matrix(yt, s > 0.5))            # [[VN FP] [FN VP]] = [[140 18] [26 116]]
print(round(roc_auc_score(yt, s), 4))           # 0.9395
```

Attention : scikit-learn range la matrice avec la classe 0 en premier, à l'inverse du tableau du cours.

8

TP en salle

TP1 – Erreur de Bayes, sur-apprentissage, évaluation

TP1 – à faire en salle — 30 min · `notebooks/TP1.ipynb` (Colab)

Partie A (régression) : $n = 200$ points de $Y = \sin(2\pi X) + \varepsilon$, $\sigma = 0{,}3$.

1. Ajuster des arbres de profondeur 1 à 15 ; tracer les erreurs d'apprentissage et test ; comparer à σ^2.
2. Refaire l'apprentissage sur 20 échantillons tirés avec remise : comparer les arbres de profondeur 15 et 3. Lequel varie le plus ?

Partie B (classification) : les deux nuages gaussiens du cours.

3. Comparer les taux d'erreur test de la logistique, d'un arbre profond et du classifieur de Bayes ($R^* \approx 0{,}144$).
4. Donner l'intervalle de confiance à $95\,\%$ de chaque taux d'erreur.
5. Choisir la profondeur d'un arbre par validation croisée ; tracer la courbe ROC et calculer l'AUC.

Résumé

- Un problème supervisé : prédire Y à partir de X, à l'aide d'un échantillon d'exemples.
- On mesure l'erreur par une perte ; le risque est l'erreur moyenne sur la population.
- Le meilleur prédicteur possible : la moyenne conditionnelle $\mathbb{E}[Y \mid X = x]$ en régression, la classe la plus probable en classification. Son erreur R^* est irréductible.
- Un modèle trop complexe apprend le bruit : l'erreur d'apprentissage ment, l'erreur test non.
- On choisit sur une validation (ou par validation croisée), on mesure une seule fois sur le test.
- Précision, rappel et AUC complètent le taux d'erreur, surtout si les classes sont déséquilibrées.