

CNFSDP

Centre National de Formation en Statistique,
Démographie et Planification
Brazzaville, République du Congo

Introduction au Machine Learning

Chapitre 4 – Apprentissage non supervisé

Analyse en composantes principales, k-means, classification hiérarchique

Rois Céti DIMBAMBA
Ingénieur statisticien économiste · Actuaire · CV en ligne

Licence 3 · Semestre 5 · UE Informatique IV
Année académique 2026-2027 · 22 octobre 2026

Plan et objectifs

1. Apprendre sans variable cible
2. L'analyse en composantes principales
3. Les k-means
4. La classification hiérarchique
5. Repérer l'atypique
6. En Python
7. TP en salle

Objectifs de la séance

- Résumer un tableau de nombreuses variables par l'ACP ; lire valeurs propres et cercle des corrélations.
- Comprendre comment se construit l'indice de richesse des enquêtes DHS.
- Regrouper des individus avec k-means et la classification hiérarchique.
- Choisir le nombre de groupes ; repérer des observations atypiques.

Prérequis : chapitre 0 (matrice de covariance, valeurs et vecteurs propres) et chapitre 1 (la moyenne est la meilleure constante).

1

Apprendre sans variable cible

Le non supervisé

Définition 4.1 (Apprentissage non supervisé). On observe seulement des variables $x_1, \ldots, x_n \in \mathbb{R}^d$, sans variable cible y. On cherche une *structure* dans les données : des directions qui résument l'information, ou des groupes d'individus qui se ressemblent.

Tâche	**Méthodes**	**Exemple en statistique publique**
Réduire la dimension	ACP	indice de richesse des enquêtes DHS
Regrouper (classification non supervisée)	k-means, CAH	typologie des ménages
Repérer l'atypique	forêt d'isolement	contrôle des questionnaires saisis

Sans y, pas d'erreur de prédiction à mesurer : on juge un résultat par un critère (inertie) et par son interprétation.

2

L'analyse en composantes principales

Résumer d variables par une seule

On part du tableau centré X (n lignes, d colonnes, chaque colonne de moyenne nulle) et de sa matrice de covariance $S = \frac{1}{n} X^\top X$ (chapitre 0).

Définition 4.2 (Composante, variance projetée). Pour une direction $u \in \mathbb{R}^d$ de norme 1, la *composante* $c = Xu$ donne à chaque individu le score $c_i = u_1 x_{i1} + \cdots + u_d x_{id}$. Sa variance vaut $\frac{1}{n} \|Xu\|^2 = u^\top S u$.

Définition 4.3 (Axes principaux). Le *premier axe* est la direction u_1, de norme 1, qui rend la variance $u^\top S u$ maximale. Le deuxième axe maximise la même variance parmi les directions orthogonales à u_1, et ainsi de suite.

La contrainte $\|u\| = 1$ est indispensable : sans elle, on augmenterait la variance en allongeant u.

Le résultat central

Théorème 4.4 (Axes de l'ACP, admis)

Les axes principaux sont les vecteurs propres de S, rangés selon leurs valeurs propres $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0$. La variance de la k-ième composante vaut λ_k.

Définition 4.5 (Inertie). L'*inertie totale* est la somme des variances des d variables. Elle vaut $\lambda_1 + \cdots + \lambda_d$ (admis). La part d'inertie *expliquée* par l'axe k est

$$\frac{\lambda_k}{\lambda_1 + \cdots + \lambda_d}.$$

À retenir

Faire une ACP, c'est diagonaliser la matrice de covariance : l'ordinateur le fait en une ligne (`np.linalg.eigh`, chapitre 0).

Une ACP à la main

4 ménages, deux scores centrés : logement x_1 et équipement x_2 ; points $(-2,-1)$, $(-1,-2)$, $(1,2)$, $(2,1)$.

$$S = \frac{1}{4} X^\top X = \frac{1}{4} \begin{pmatrix} 4+1+1+4 & 2+2+2+2 \\ 2+2+2+2 & 1+4+4+1 \end{pmatrix} = \begin{pmatrix} 2{,}5 & 2 \\ 2 & 2{,}5 \end{pmatrix}.$$

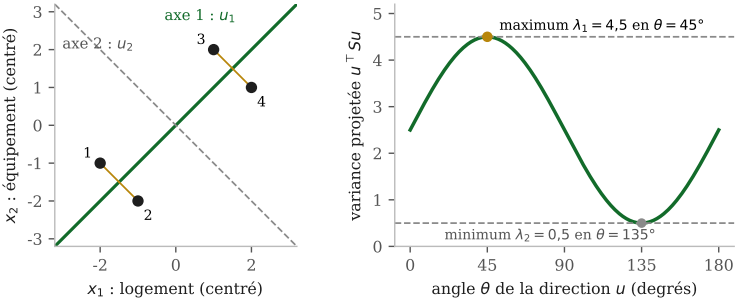
Toute direction de norme 1 s'écrit $u = (\cos\theta, \sin\theta)$. Alors

$$u^\top S u = 2{,}5\cos^2\theta + 2{,}5\sin^2\theta + 4\sin\theta\cos\theta = 2{,}5 + 2\sin 2\theta,$$

car $\cos^2\theta + \sin^2\theta = 1$ et $2\sin\theta\cos\theta = \sin 2\theta$.

- Maximum $2{,}5 + 2 = 4{,}5$ quand $\sin 2\theta = 1$, soit $\theta = 45°$: premier axe $u_1 = \frac{1}{\sqrt{2}}(1,1)$.
- Minimum $2{,}5 - 2 = 0{,}5$ quand $\theta = 135°$: deuxième axe $u_2 = \frac{1}{\sqrt{2}}(-1,1)$, orthogonal à u_1.
- Vérification : $S u_1 = 4{,}5\, u_1$ et $S u_2 = 0{,}5\, u_2$: ce sont bien les vecteurs propres, et $\lambda_1 = 4{,}5$, $\lambda_2 = 0{,}5$.

L'ACP à la main en image



À gauche : les 4 ménages et leurs projections (en or) sur le premier axe. À droite : la variance projetée selon la direction choisie.

- Composante 1 : $c = \frac{x_1 + x_2}{\sqrt{2}} \approx (-2{,}12;\ -2{,}12;\ 2{,}12;\ 2{,}12)$, de variance $4{,}5$.
- Part d'inertie expliquée : $4{,}5/(4{,}5 + 0{,}5) = 90\,\%$: un seul score résume presque tout.

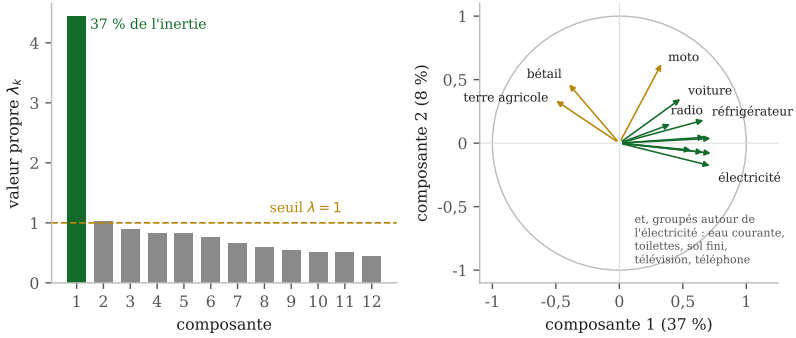
ACP normée

Définition 4.6 (ACP normée). Quand les variables n'ont pas la même unité (revenu en FCFA, taille du ménage, années d'études), on les *standardise* avant l'ACP : chaque colonne est centrée et divisée par son écart type. S devient la matrice des corrélations, et l'inertie totale vaut d.

- Sans standardisation, la variable de plus grande variance (le revenu en FCFA) accaparerait le premier axe.
- Pour des variables binaires (le ménage possède ou non un bien), on standardise aussi : c'est la pratique de l'indice de richesse DHS.

Combien d'axes garder ?. On regarde l'*éboulis* des valeurs propres et l'on garde les premiers axes, avant le « coude ». En ACP normée, on garde souvent les axes de valeur propre supérieure à 1 (règle de Kaiser), ou assez d'axes pour expliquer 70 à $80\,\%$ de l'inertie.

Lire une ACP : éboulis et cercle des corrélations



$2\,000$ ménages fictifs, 12 biens codés $0/1$ (électricité, eau courante…, bétail). Chaque flèche donne les corrélations d'un bien avec les deux composantes. L'axe 1 ($37\,\%$ de l'inertie) oppose les ménages sans équipement aux ménages équipés : c'est un axe de *richesse*. L'axe 2 ($8\,\%$) distingue les biens ruraux (bétail, terre, moto).

Application : l'indice de richesse des enquêtes DHS

Les enquêtes démographiques et de santé ne mesurent pas le revenu. Elles construisent un *indice de richesse* :

1. on relève les biens et les caractéristiques du logement de chaque ménage ;
2. on fait une ACP normée sur ces variables ;
3. le score de la **première composante** est l'indice de richesse ;
4. on découpe l'indice en **quintiles** (les 20 % les plus pauvres, etc.).

Exemple. [Ménages fictifs] La richesse « cachée » qui a servi à simuler les biens est connue ici : sa corrélation avec la composante 1 vaut $0{,}895$.

Part des ménages avec réfrigérateur, par quintile :

Q1	Q2	Q3	Q4	Q5
$1\,\%$	$4\,\%$	$17\,\%$	$48\,\%$	$91\,\%$

Projet : avec l'EDS Congo 2011-2012, vous pourrez reconstruire cet indice et le comparer à celui publié (variables `hv270`, `hv271`).

3

Les k-means

Regrouper : le critère d'inertie

Définition 4.7 (Classification en k groupes, inertie intra-classe). On cherche une partition des n individus en k groupes $G_1, \ldots, G_k$. Chaque groupe a pour *centre* la moyenne c_j de ses individus. L'*inertie intra-classe*

$$W = \sum_{j=1}^{k} \sum_{i \in G_j} \|x_i - c_j\|^2$$

mesure la dispersion des individus autour du centre de leur groupe. On cherche la partition qui rend W minimal.

- Des groupes compacts ont une petite inertie intra-classe.
- Essayer toutes les partitions est impossible : avec $n = 100$ et $k = 3$, il y en a plus de 10^{46}.
- On utilise donc un algorithme qui améliore W pas à pas.

L'algorithme de Lloyd (k-means)

Définition 4.8 (k-means). On choisit k centres de départ $c_1, \dots, c_k$, puis on répète jusqu'à ce que plus rien ne change :

1. **Affectation** : chaque individu rejoint le groupe du centre le plus proche ;
2. **Mise à jour** : chaque centre devient la moyenne des individus de son groupe.

Proposition 4.9

Aucune des deux étapes ne fait augmenter l'inertie intra-classe W.

Preuve. **Affectation** : chaque terme $\|x_i - c\|^2$ est remplacé par la plus petite des distances aux centres, donc ne peut que baisser. **Mise à jour** : dans chaque groupe, la somme $\sum_i \|x_i - c\|^2$ est minimale quand c est la moyenne du groupe (la moyenne est la meilleure constante, chapitre 1, appliqué à chaque coordonnée). □

Le nombre de partitions étant fini, l'algorithme s'arrête après un nombre fini d'itérations.

k-means à la main

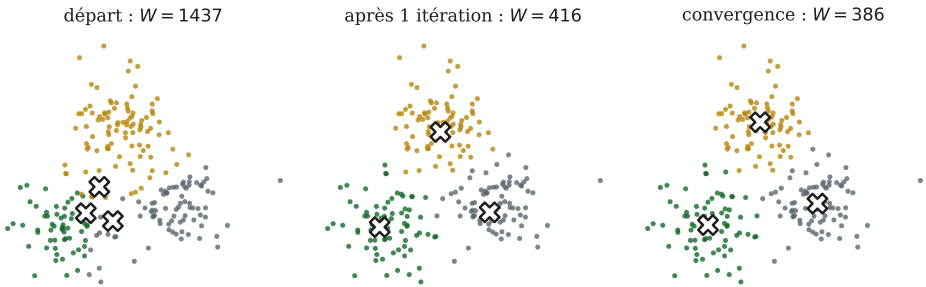
Revenus mensuels de 6 ménages (centaines de milliers de FCFA, fictifs) : $1,\ 2,\ 4,\ 6,\ 9,\ 12$. On prend $k = 2$ et les centres de départ 1 et 2.

itération	centres	groupes après affectation	W
0	1 et 2	$\{1\}$; $\{2, 4, 6, 9, 12\}$	169
1	1 et 6,6	$\{1, 2\}$; $\{4, 6, 9, 12\}$	43,04
2	1,5 et 7,75	$\{1, 2, 4\}$; $\{6, 9, 12\}$	29,44
3	2,33 et 9	$\{1, 2, 4\}$; $\{6, 9, 12\}$ (inchangés)	22,67

W est calculé avec les centres de la ligne ; dernière ligne : $1{,}78 + 0{,}11 + 2{,}78 + 9 + 0 + 9 \approx 22{,}67$.

Un minimum seulement local. La partition $\{1, 2, 4, 6\}$; $\{9, 12\}$ a une inertie plus faible, $W = 19{,}25$, et elle est aussi stable pour l'algorithme. Le résultat dépend du départ : on relance k-means avec plusieurs départs (`n_init`) et l'on garde le meilleur W.

Lloyd en deux dimensions



240 points simulés en trois paquets ; les croix sont les centres. Partis de mauvais centres, regroupés en bas à gauche, ceux-ci migrent vers les trois paquets : W passe de $1\,437$ à 386.

En pratique, scikit-learn choisit des départs bien écartés (k-means++) et relance l'algorithme plusieurs fois. Comme pour le k-NN, on standardise les variables avant de calculer des distances.

Choisir le nombre de groupes

Coude. $W(k)$ baisse toujours quand k augmente ($W = 0$ si chaque individu est seul) : on cherche le k après lequel la baisse devient faible.

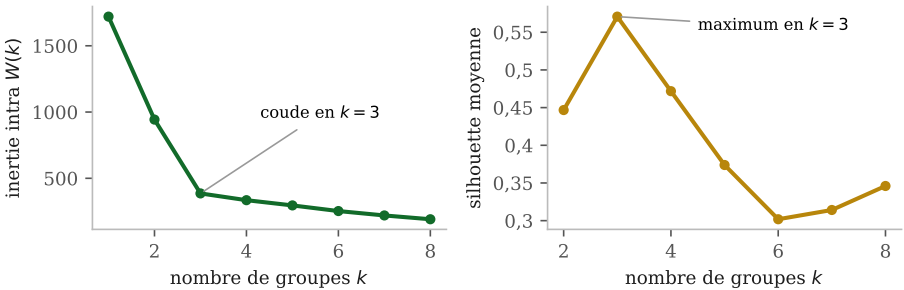
Définition 4.10 (Silhouette). Pour l'individu i, soit a sa distance moyenne aux membres de son groupe et b sa distance moyenne aux membres du groupe voisin le plus proche :

$$s(i) = \frac{b - a}{\max(a, b)} \in [-1, 1].$$

Proche de 1 : bien classé ; négatif : plus proche de l'autre groupe. On choisit le k qui maximise la silhouette moyenne.

Exemple. Partition $\{1, 2, 4, 6\}$; $\{9, 12\}$, ménage de revenu 4 : $a = \frac{3+2+2}{3} \approx 2{,}33$, $b = \frac{5+8}{2} = 6{,}5$, d'où $s = \frac{6{,}5-2{,}33}{6{,}5} \approx 0{,}64$: bien classé.

Coude et silhouette en pratique



Les 240 points en trois paquets de la diapositive précédente : $W(k)$ chute jusqu'à $k = 3$ puis baisse lentement, et la silhouette est maximale en $k = 3$. Sur des données réelles, les critères sont rarement aussi nets : on les croise avec l'interprétation des groupes.

4

La classification hiérarchique

Classification ascendante hiérarchique (CAH)

Définition 4.11 (CAH, critère de Ward). On part de n groupes d'un seul individu. À chaque étape, on fusionne les deux groupes A et B dont la fusion fait le moins augmenter l'inertie intra-classe. Avec le critère de Ward, cette hausse vaut (admis)

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \, \|c_A - c_B\|^2 ,$$

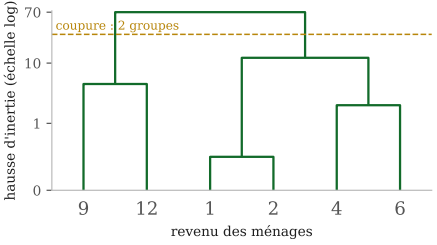
où n_A, n_B sont les effectifs et c_A, c_B les centres. On s'arrête quand il ne reste qu'un groupe.

- L'historique des fusions se dessine en *dendrogramme* : la hauteur d'une fusion est son coût Δ.
- On coupe l'arbre là où les fusions deviennent chères : on obtient le nombre de groupes.
- Pas de départ au hasard : le résultat est toujours le même.

CAH à la main sur les six ménages

étape	fusion	hausse Δ
1	$\{1\}+\{2\}$	$\frac{1\times1}{2}\times 1^2 = 0{,}5$
2	$\{4\}+\{6\}$	$\frac{1}{2}\times 2^2 = 2$
3	$\{9\}+\{12\}$	$\frac{1}{2}\times 3^2 = 4{,}5$
4	$\{1,2\}+\{4,6\}$	$\frac{2\times2}{4}\times 3{,}5^2 = 12{,}25$
5	$\{1,2,4,6\}+\{9,12\}$	$\frac{4\times2}{6}\times 7{,}25^2 \approx 70{,}08$

En coupant avant la dernière fusion, très chère, on obtient 2 groupes : $\{1,2,4,6\}$ et $\{9,12\}$, d'inertie intra $0{,}5+2+12{,}25+4{,}5 = 19{,}25$.



La CAH retrouve ici la meilleure partition, que k-means parti de 1 et 2 avait manquée.

Inertie totale, intra et inter

Proposition 4.12 (Décomposition de Huygens, admise)

Pour toute partition, l'inertie totale $T = \sum_i \|x_i - \bar{x}\|^2$ se décompose en

$$T = \underbrace{\sum_j \sum_{i \in G_j} \|x_i - c_j\|^2}_{W \text{ : intra-classe}} + \underbrace{\sum_j n_j \, \|c_j - \bar{x}\|^2}_{B \text{ : inter-classe}} .$$

Vérification : moyenne $\bar{x} = \frac{34}{6} \approx 5{,}67$ et $T \approx 89{,}33$. Pour $\{1, 2, 4, 6\}$; $\{9, 12\}$: $W = 19{,}25$ et $B = 4 \times (3{,}25 - 5{,}67)^2 + 2 \times (10{,}5 - 5{,}67)^2 \approx 70{,}08$, d'où $W + B = 89{,}33$.

Lecture. T ne dépend pas de la partition : minimiser l'inertie intra revient à maximiser l'inertie inter, c'est-à-dire à séparer les groupes. La part B/T (ici $78\,\%$) mesure la qualité d'une partition, comme un R^2.

k-means ou CAH ?

	k-means	**CAH (Ward)**
Nombre de groupes	fixé à l'avance	choisi en coupant le dendrogramme
Résultat	dépend du départ (minimum local)	toujours le même
Grands effectifs	rapide, même pour $n = 100\,000$	lent : compare tous les groupes deux à deux
Forme des groupes	groupes compacts, de tailles voisines	idem avec Ward

À retenir

Stratégie classique : ACP pour résumer les variables, puis CAH ou k-means sur les premières composantes, puis description de chaque groupe par les moyennes des variables d'origine.

Une typologie de ménages

k-means à 3 groupes sur les deux premières composantes des $2\,000$ ménages fictifs. Part des ménages possédant le bien :

groupe	effectif	électricité	voiture	bétail
ménages ruraux peu équipés	870	$21\,\%$	$1\,\%$	$55\,\%$
ménages équipés sans véhicule	715	$90\,\%$	$3\,\%$	$14\,\%$
ménages aisés	415	$96\,\%$	$55\,\%$	$23\,\%$

- On nomme les groupes *après coup*, en lisant leurs moyennes : l'algorithme ne connaît que des numéros.
- La CAH de Ward donne le même groupe pour $91\,\%$ des ménages.
- La silhouette préférerait 2 groupes ; 3 groupes restent lisibles. Le choix final mêle critères et interprétation.

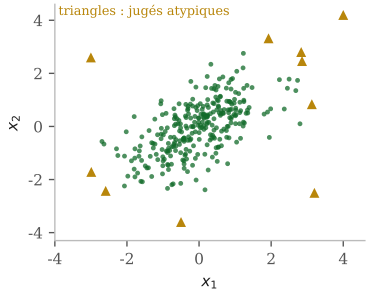
5

Repérer l'atypique

La forêt d'isolement

Définition 4.13 (Forêt d'isolement). On construit de nombreux arbres *au hasard* (variable et seuil tirés au sort à chaque nœud) jusqu'à isoler chaque individu. Un individu atypique est isolé en *peu* de coupures : son score d'anomalie est élevé si sa profondeur moyenne d'isolement est faible.

- Méthode d'ensemble (chapitre 3), sans variable cible.
- Usages : contrôle de saisie des questionnaires, fraudes, valeurs aberrantes.
- Ménages fictifs : les $1\,\%$ les plus atypiques mêlent biens « urbains » (réfrigérateur, voiture) et « ruraux » (bétail, moto).
- Atypique ne veut pas dire faux : on vérifie avant d'exclure.



300 points simulés et 5 points ajoutés à l'écart.

6

En Python

ACP et indice de richesse

```python
import numpy as np, pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

biens, richesse, urbain = simuler_menages()      # TP4 : 2 000 ménages fictifs, 12 biens (0/1)
Z = StandardScaler().fit_transform(biens)        # ACP normée
acp = PCA().fit(Z)
print(acp.explained_variance_[:3].round(2))      # valeurs propres : [4.43 1.02 0.88]
print(acp.explained_variance_ratio_[:2].round(3))  # parts d'inertie : [0.369 0.085]
indice = acp.transform(Z)[:, 0]                  # indice de richesse = composante 1
if np.corrcoef(indice, biens["electricite"])[0, 1] < 0:
    indice = -indice                             # orienter : plus riche = plus grand
print(round(np.corrcoef(indice, richesse)[0, 1], 3))   # lien avec la richesse cachée : 0.895
quintile = pd.qcut(indice, 5, labels=False) + 1
print(biens.groupby(quintile)["refrigerateur"].mean().round(2).values)
# [0.01 0.04 0.17 0.48 0.91]
```

Le signe d'une composante est arbitraire : on l'oriente pour que l'indice croisse avec la richesse.

k-means, CAH et forêt d'isolement

```python
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.metrics import silhouette_score
from sklearn.ensemble import IsolationForest

C = acp.transform(Z)[:, :2]                        # deux premières composantes
for k in [2, 3, 4, 5]:
    km = KMeans(n_clusters=k, n_init=10, random_state=0).fit(C)
    print(k, round(km.inertia_), round(silhouette_score(C, km.labels_), 3))
# 2 4129 0.516 | 3 2771 0.454 | 4 2075 0.398 | 5 1634 0.426
km = KMeans(n_clusters=3, n_init=10, random_state=0).fit(C)
cah = AgglomerativeClustering(n_clusters=3, linkage="ward").fit(C)
print(pd.crosstab(km.labels_, cah.labels_))       # 91 % des ménages dans le même groupe
print(biens.groupby(km.labels_)[["electricite", "voiture", "betail"]].mean().round(2))
iso = IsolationForest(contamination=0.01, random_state=0).fit(Z)
print(biens[iso.predict(Z) == -1].mean().round(2))      # profil des 20 ménages atypiques
```

`contamination` fixe la part d'individus déclarés atypiques ($1\,\%$ ici).

7

TP en salle

TP4 – ACP, k-means, CAH

TP4 – à faire en salle — 45 min · `notebooks/TP4.ipynb` (Colab)

1. **ACP à la main** : pour les 4 ménages du cours, calculer S, ses valeurs et vecteurs propres, et tracer $u^\top S u$ en fonction de l'angle.
2. **Indice de richesse** : ACP normée des $2\,000$ ménages fictifs ; éboulis, corrélations avec les axes, indice et quintiles ; comparer à la richesse cachée.
3. **Lloyd en NumPy** : programmer k-means sur les 6 revenus ; partir des centres 1 et 2, puis 3 et 11 ; comparer les inerties.
4. **Nombre de groupes** : coude et silhouette pour $k = 2, \dots, 8$ sur les ménages ; décrire les groupes retenus.
5. **CAH** : dendrogramme des 6 revenus avec `scipy` ; retrouver les coûts de fusion du cours ; vérifier $T = W + B$.
6. **Forêt d'isolement** : repérer les $1\,\%$ de ménages les plus atypiques et décrire leur profil.

Résumé

- Non supervisé : pas de y ; on cherche des directions (ACP) ou des groupes (k-means, CAH).
- ACP : axes = vecteurs propres de la covariance, variances = valeurs propres ; standardiser si les unités diffèrent ; lire l'éboulis et les corrélations avec les axes.
- L'indice de richesse DHS est la première composante d'une ACP sur les biens des ménages.
- k-means : affectation au centre le plus proche, puis centres = moyennes ; l'inertie intra ne remonte jamais, mais le minimum peut n'être que local.
- CAH de Ward : fusions successives au moindre coût d'inertie ; dendrogramme ; résultat déterministe.
- $T = W + B$: bien regrouper, c'est séparer les groupes. On choisit k par le coude, la silhouette et l'interprétation.
- Forêt d'isolement : les individus isolés en peu de coupures sont atypiques.