CNFSDP

Centre National de Formation en Statistique,
Démographie et Planification
Brazzaville, République du Congo

Introduction au Machine Learning

Chapitre 5 – Projet de bout en bout, interprétabilité et éthique

Des données d'enquête à un modèle que l'on peut expliquer et défendre

Rois Céti DIMBAMBA

Ingénieur statisticien économiste · Actuaire · CV en ligne

Licence 3 · Semestre 5 · UE Informatique IV

Année académique 2026-2027 · ?? novembre 2026

Plan et objectifs

1. La démarche d'un projet
2. Lire et préparer des données d'enquête
3. Les fuites d'information
4. Interpréter un modèle
5. Confidentialité
6. Équité
7. Le projet de groupe
8. En Python
9. TP en salle

Objectifs de la séance

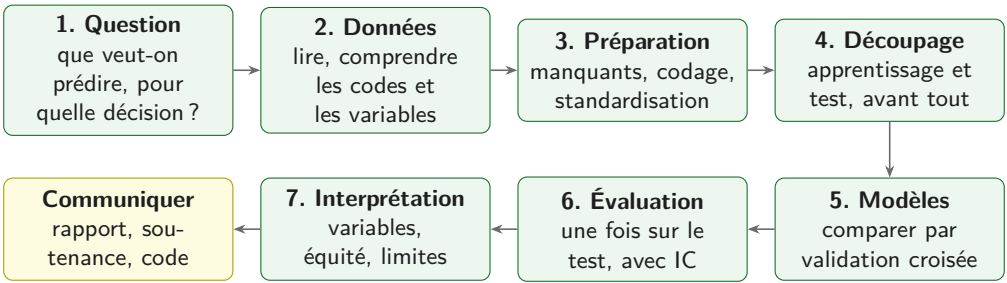
- Mener un projet complet : question, données d'enquête, préparation, modèles, évaluation.
- Construire un *pipeline* et éviter les fuites d'information.
- Expliquer un modèle : importance des variables, dépendance partielle.
- Protéger les personnes enquêtées et vérifier l'équité d'un modèle.
- Lancer le projet de groupe sur l'EDS Congo.

Prérequis : chapitres 1 à 4.

1

La démarche d'un projet

Sept étapes



Exemple. [Fil rouge du chapitre] Prédire si un enfant de 12 à 23 mois a reçu toutes ses vaccinations, pour cibler les relances des agents de santé. Les données sont *fictives* mais ont la forme du fichier « enfants » (KR) des enquêtes DHS : $3\,000$ enfants.

Poser la bonne question

- **Quelle décision ?** Relancer les familles dont l'enfant risque de ne pas être vacciné. Le modèle sert à *classer* les enfants par priorité.
- **Quelles variables sont disponibles au moment de la décision ?** Région, milieu, instruction de la mère, richesse, lieu d'accouchement, visites prénatales… mais pas le nombre de doses déjà reçues, qui définit la réponse.
- **Quelle erreur coûte le plus ?** Oublier un enfant non vacciné (faux négatif) plutôt qu'une relance inutile : on regardera le rappel (chapitre 1).
- **Prédire ou expliquer ?** Un bon prédicteur n'indique pas de causes : « la richesse prédit la vaccination » ne dit pas que distribuer de l'argent ferait vacciner.

À retenir

La question fixe la cible, les variables autorisées et la métrique. Elle se décide *avant* de toucher aux données.

2

Lire et préparer des données d'enquête

Les fichiers des enquêtes DHS

- Un fichier par unité : ménages (`HR`), femmes (`IR`), hommes (`MR`), enfants (`KR`)…
- Noms standard : `CGKR61FL.DTA` = Congo, enfants, enquête 6, Stata.
- Formats Stata (`.DTA`) et SPSS (`.SAV`) : chaque variable est un *code* accompagné d'*étiquettes*.
- Codes spéciaux : 98 = « ne sait pas », 99 = manquant ; à transformer en valeurs manquantes.
- Poids de sondage `v005` (à diviser par 10^6) pour les statistiques descriptives.

variable	**contenu**
`v024`, `v025`	région, milieu
`v106`	instruction de la mère
`v190`	quintile de richesse
`b4`, `bord`	sexe, rang de naissance
`m14`, `m15`	visites prénatales, lieu
`v467d`	distance au centre de santé
`h2` à `h9`	vaccins reçus

Toujours vérifier dans le dictionnaire de l'enquête.

Préparer les variables

Définition 5.1 (Codage en indicatrices (*one-hot*)). Une variable qualitative à m modalités est remplacée par m variables $0/1$, une par modalité. Exemple pour le lieu d'accouchement :

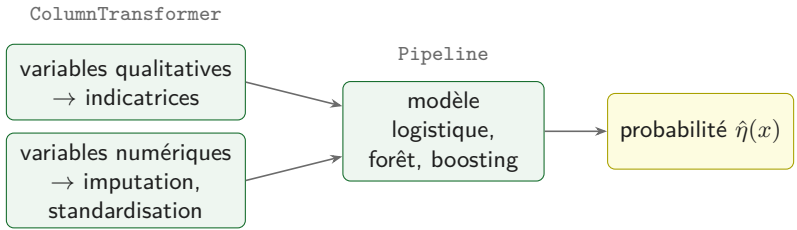
`m15`	domicile	hôpital public	clinique privée	autre
hôpital public (21)	0	1	0	0
domicile (11)	1	0	0	0

Définition 5.2 (Imputation, standardisation). *Imputer*, c'est remplacer une valeur manquante, par exemple par la médiane de la variable. *Standardiser*, c'est soustraire la moyenne et diviser par l'écart type (chapitres 2 à 4).

Ne jamais utiliser un code comme 11 ou 21 comme un nombre : « clinique privée (31) » n'est pas « trois fois domicile ».

Le pipeline : enchaîner sans tricher

Définition 5.3 (Pipeline). Un *pipeline* enchaîne la préparation et le modèle en un seul objet. Toutes les quantités de la préparation (médianes, moyennes, écarts types, modalités) sont apprises *sur l'échantillon d'apprentissage seulement*, puis appliquées telles quelles au test.



Avec un pipeline, la validation croisée refait toute la préparation dans chaque bloc : l'estimation de l'erreur reste honnête.

Comparer trois modèles

Fil rouge : $2\,100$ enfants pour l'apprentissage, 900 pour le test. Même pipeline de préparation, trois modèles, AUC par validation croisée à 5 blocs :

modèle	AUC (validation croisée)	commentaire
régression logistique	$\mathbf{0{,}805}$	simple, coefficients lisibles
forêt aléatoire	$0{,}796$	
gradient boosting	$0{,}787$	

Sur le test, une seule fois : la logistique atteint une AUC de $0{,}824$ et une exactitude de $0{,}743$.

Lecture. Les écarts sont faibles. À performance voisine, on préfère le modèle le plus simple et le plus explicable : ici la logistique. Les méthodes d'ensemble gagnent quand les relations sont très non linéaires (chapitres 2 et 3).

3

Les fuites d'information

Qu'est-ce qu'une fuite ?

Définition 5.4 (Fuite d'information). Il y a *fuite* quand l'apprentissage utilise une information qui ne serait pas disponible au moment de prédire, ou qui vient de l'échantillon de test. L'erreur estimée devient trop optimiste.

Fuite n° 1 : une variable qui contient la réponse.

Le fichier contient `nb_doses`, le nombre de doses reçues sur 8. Or « vaccination complète » signifie justement `nb_doses` $= 8$.

variables utilisées	AUC (validation croisée)
variables du fil rouge	$0{,}805$
les mêmes + `nb_doses`	$\mathbf{1{,}000}$

Un score parfait doit éveiller le soupçon : au moment de relancer une famille, on ne connaît pas encore ses doses.

Une fuite plus discrète : préparer avant de découper

Fuite n° 2. 200 individus, $2\,000$ variables de *pur bruit*, une cible tirée à pile ou face : aucune méthode ne peut faire mieux que $50\,\%$ de bonnes réponses.

procédure	exactitude estimée
on choisit les 20 variables les plus liées à y sur *toutes* les données, puis validation croisée	$0{,}755$
le choix des 20 variables est fait *dans* le pipeline, bloc par bloc	$0{,}555$

La première procédure a « vu » les blocs de validation en choisissant les variables : elle annonce $75\,\%$ de réussite sur du hasard.

À retenir

Règles : découper d'abord ; toute étape apprise sur les données (sélection, imputation, standardisation, choix de réglages) va dans le pipeline ; le test ne sert qu'une fois.

4

Interpréter un modèle

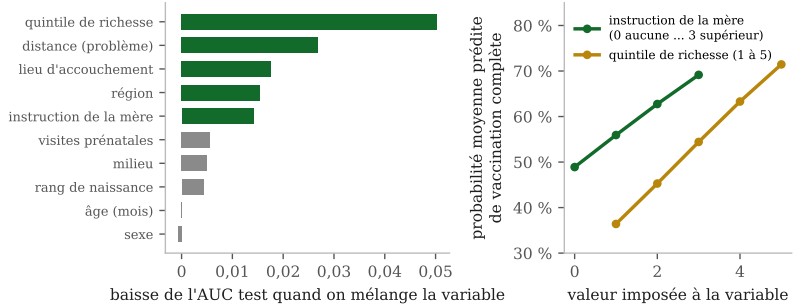
Deux outils d'interprétation

Définition 5.5 (Importance par permutation). Pour la variable x_j : on mélange au hasard sa colonne dans les données test, ce qui casse son lien avec y, et l'on mesure la baisse de performance (ici de l'AUC). On répète plusieurs fois et l'on fait la moyenne.

Définition 5.6 (Dépendance partielle). Pour une valeur v de la variable x_j : on impose $x_j = v$ à *tous* les individus, sans changer leurs autres variables, et l'on calcule la probabilité moyenne prédite. La courbe obtenue en faisant varier v montre l'effet moyen de x_j dans le modèle.

Ces deux outils marchent pour n'importe quel modèle : logistique, forêt, boosting.

Ce que dit le modèle du fil rouge



Le quintile de richesse, la distance au centre de santé et le lieu d'accouchement sont les variables les plus utiles. Le sexe et l'âge de l'enfant n'apportent rien. En passant d'une mère sans instruction à une mère du supérieur, la probabilité moyenne prédite passe de 49 à $69\,\%$.

Précautions : ce sont des *associations* ; deux variables corrélées (instruction et richesse) se partagent l'importance.

5

Confidentialité

Protéger les personnes enquêtées

Retirer les noms ne suffit pas. Des variables anodines, croisées, désignent une personne : ce sont des *quasi-identifiants*.

Fil rouge : en croisant région, milieu, sexe, âge en mois, rang de naissance et instruction de la mère, $37\,\%$ **des enfants** sont seuls dans leur case, et $86\,\%$ sont dans une case d'au plus 3 enfants.

Un voisin qui connaît ces six informations retrouverait la ligne de l'enfant, et donc ses réponses de santé.

À retenir

Conditions d'usage des données DHS :

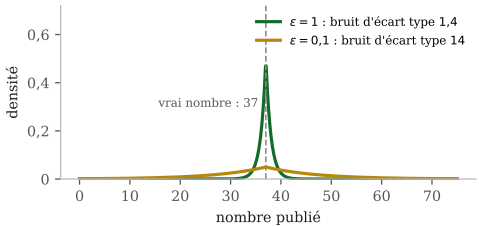
- usage limité au projet déclaré ;
- fichiers reçus de l'enseignant, jamais retransmis, même dans un groupe ;
- aucune tentative d'identifier une personne ou un ménage ;
- fichiers jamais déposés sur GitHub ni envoyés par courriel.

Publier un chiffre sans trahir personne

Définition 5.7 (Mécanisme de Laplace). Pour publier un comptage N (par exemple le nombre d'enfants non vaccinés d'un district), on publie $N + B$, où le bruit B suit une loi de Laplace de paramètre $\frac{1}{\varepsilon}$: moyenne 0, écart type $\frac{\sqrt{2}}{\varepsilon}$.

Proposition 5.8 (admise)

Ajouter ou retirer une personne change N d'au plus 1. Avec ce bruit, la loi du chiffre publié change alors d'un facteur au plus e^{ε} : c'est la *confidentialité différentielle* de niveau ε.



Petit ε : forte protection, chiffre moins précis.

Le recensement des États-Unis de 2020 a été publié ainsi. L'arbitrage entre précision et protection est un choix public.

6

Équité

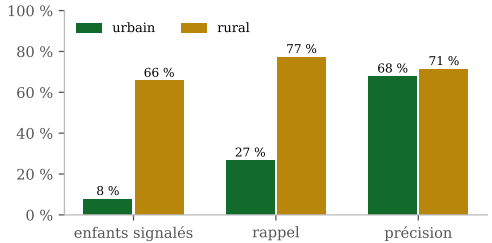
Un modèle peut-il être injuste ?

Le modèle signale les enfants à relancer (prédit « non vacciné »). Sur les 900 enfants test, selon le milieu :

milieu	enfants	non vaccinés	VP	FN	FP	VN
urbain	400	79	21	58	10	311
rural	500	303	234	69	94	103

Définition 5.9 (Trois critères d'équité).
Entre deux groupes, on compare :

- la part d'individus signalés (*parité*) ;
- le rappel (*égalité des chances*) ;
- la précision (*calibration*).



Lire l'audit d'équité

- **Précision voisine** (68 et $71\,\%$) : un enfant signalé l'est à raison aussi souvent en ville qu'à la campagne.
- **Rappel très différent** : $77\,\%$ des enfants ruraux non vaccinés sont repérés, mais $27\,\%$ seulement des urbains (21 sur 79) : en ville, ils ressemblent aux vaccinés.
- **Signalements** : $66\,\%$ en milieu rural, $8\,\%$ en ville, car les taux de vaccination diffèrent vraiment.

Proposition 5.10 (admise)

Si la part de positifs diffère entre deux groupes, un classifieur imparfait ne peut pas égaliser à la fois précision, rappel et taux de faux positifs.

À retenir

On choisit le critère selon l'usage. Pour une campagne de vaccination, oublier un enfant est grave : on vise des rappels égaux (par exemple un seuil par milieu), et on l'écrit dans le rapport.

7

Le projet de groupe

Le projet : organisation et livrables

Groupes : 36 étudiants, 9 groupes de 4, une variante différente par groupe.

Données : EDS Congo 2011-2012 (DHS), fichiers originaux.

Sujet : sur la variante du groupe,

- une question de *prédiction* (chapitres 1 à 3), modèles comparés par validation croisée ;
- une analyse *non supervisée* (chapitre 4) : ACP, typologie ;
- une courte discussion des limites.

Évaluation du cours	**poids**
examen sur table (3 h)	$40\,\%$
rapport de 10 pages + notebook	$40\,\%$
soutenance de 15 min	$20\,\%$

Calendrier : remise du rapport et soutenances **fin novembre 2026**, deux à trois semaines après ce chapitre (dates exactes en salle).

À la soutenance, chacun des quatre membres présente une partie.

Neuf groupes, neuf variantes

gr.	thème	fichier	cible à prédire	variante
1	richesse	`HR`	ménage dans les 40 % les plus pauvres	indice national (ACP), comparé à `hv271`
2	richesse	`HR`	ménage dans les 40 % les plus pauvres	indices urbain et rural séparés
3	vaccination	`KR`	vaccination complète (`h2` à `h9`)	enfants de 12 à 23 mois
4	vaccination	`KR`	abandon : DTC1 reçu, DTC3 non	enfants de 12 à 23 mois
5	vaccination	`KR`	rougeole (`h9`)	enfants de 12 à 23 mois
6	nutrition	`KR`	retard de croissance ($\texttt{hw70} < -200$)	enfants de moins de 5 ans
7	nutrition	`KR`	insuffisance pondérale ($\texttt{hw71} < -200$)	enfants de moins de 5 ans
8	femme	`IR`	contraception moderne ($\texttt{v313} = 3$)	femmes en union
9	femme	`IR`	besoins non satisfaits en contraception	femmes en union

Attribution en salle. Codes à vérifier dans le dictionnaire (exclure les codes ≥ 9996 de `hw70`, `hw71`). Groupes 1 et 2 : prédire la pauvreté avec des variables hors indice (taille du ménage, chef de ménage, région).

Obtenir les données DHS

1. L'enseignant a demandé au programme DHS une **autorisation pour toute la classe** : pas de compte à créer pour les étudiants.
2. Chaque étudiant signe la **charte d'utilisation** du *Guide du projet*.
3. L'enseignant remet les fichiers (Stata ou SPSS : `HR`, `IR`, `KR`) et le dictionnaire des variables, par un canal privé.
4. Chacun range les fichiers dans un dossier `donnees/` déclaré dans `.gitignore`.
5. À la fin du cours, on supprime ses copies.

À retenir

Ce qui est rendu : le code et le rapport, jamais les données. Aucun fichier DHS n'est retransmis : ni dans le groupe, ni entre groupes, ni sur Internet.

Pour un mémoire ou une recherche après le cours, la demande se fait en son nom : procédure dans le *Guide du projet*.

8

En Python

Lire un fichier DHS avec pandas

```python
import numpy as np, pandas as pd
fichier = "donnees/ZZKR_FICTIF.DTA"                    # sur l'EDS Congo : CGKR61FL.DTA
with pd.io.stata.StataReader(fichier) as lecteur:
    etiquettes = lecteur.value_labels()                # codes -> libellés
    libelles = lecteur.variable_labels()               # nom long de chaque variable
print(libelles["v106"], etiquettes["v106"])
colonnes = ["v024", "v025", "v106", "v190", "b4", "bord", "hw1", "m14", "m15", "v467d",
            "vacc_complet"]
df = pd.read_stata(fichier, columns=colonnes, convert_categoricals=False)
df["m14"] = df["m14"].replace(98, np.nan)              # 98 = « ne sait pas » -> manquant
print(df.shape, round(df["vacc_complet"].mean(), 3), df["m14"].isna().sum())
spss = pd.read_spss("donnees/ZZKR_FICTIF.SAV", usecols=colonnes)   # version SPSS (pyreadstat)
# niveau d'instruction de la mère {0: 'aucune', 1: 'primaire', 2: 'secondaire', ...}
# (3000, 11) 0.575 197
```

`columns` ne charge que les variables utiles (les vrais fichiers en ont plus de mille) ; `convert_categoricals=False` garde les codes, plus sûrs à manipuler.

Préparer dans un pipeline

```
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.pipeline import make_pipeline
from sklearn.compose import make_column_transformer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.impute import SimpleImputer

qual = ["v024", "v025", "b4", "m15", "v467d"]          # qualitatives
quant = ["v106", "v190", "bord", "hw1", "m14"]          # numériques
df[quant] = df[quant].astype(float)
X, y = df[qual + quant], df["vacc_complet"]
Xa, Xt, ya, yt = train_test_split(X, y, test_size=0.3, random_state=0, stratify=y)
prep = make_column_transformer(
    (OneHotEncoder(handle_unknown="ignore"), qual),                    # indicatrices
    (make_pipeline(SimpleImputer(strategy="median"), StandardScaler()), quant))
```

On découpe d'abord ; `prep` n'apprend ses médianes, moyennes et modalités qu'au moment du `fit`, sur l'apprentissage.

Comparer les modèles par validation croisée

```python
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier

modeles = {"logistique": LogisticRegression(max_iter=1000),
           "forêt": RandomForestClassifier(n_estimators=300, min_samples_leaf=10,
                                           random_state=0),
           "boosting": GradientBoostingClassifier(random_state=0)}
for nom, m in modeles.items():
    auc = cross_val_score(make_pipeline(prep, m), Xa, ya, cv=5, scoring="roc_auc")
    print(nom, auc.mean().round(3))
# logistique 0.805 | forêt 0.796 | boosting 0.787
```

`make_pipeline(prep, m)` : la préparation est refaite dans chaque bloc de la validation croisée, sans fuite.

Importance des variables et audit d'équité

```python
from sklearn.inspection import permutation_importance
f = make_pipeline(prep, LogisticRegression(max_iter=1000)).fit(Xa, ya)
r = permutation_importance(f, Xt, yt, scoring="roc_auc", n_repeats=20, random_state=0)
print(pd.Series(r.importances_mean, index=X.columns).nlargest(3).round(3).to_dict())
# {'v190': 0.05, 'v467d': 0.027, 'm15': 0.018}

# signalé = prédit « non vacciné »
signale = pd.Series(f.predict_proba(Xt)[:, 1] < 0.5, index=Xt.index)
non_vacc = yt == 0
for g, milieu in [(1, "urbain"), (2, "rural")]:
    m = Xt["v025"] == g
    print(milieu, round(signale[m].mean(), 2),          # part d'enfants signalés
          round(signale[m & non_vacc].mean(), 2),        # rappel
          round(non_vacc[m & signale].mean(), 2))        # précision
# urbain 0.08 0.27 0.68 | rural 0.66 0.77 0.71
```

Un audit d'équité ne demande que quelques lignes : il s'impose dès qu'un modèle sert à cibler des personnes.

9

TP en salle

TP5 – Un projet de bout en bout

TP5 – à faire en salle — 45 min · `notebooks/TP5.ipynb` (Colab)

1. **Lecture** : fabriquer le fichier fictif au format DHS (Stata et SPSS), le relire avec pandas, lire les étiquettes, recoder 98 en manquant.
2. **Pipeline** : comparer logistique, forêt et boosting par validation croisée ; évaluer le meilleur une fois sur le test.
3. **Fuites** : ajouter `nb_doses` ; refaire l'expérience des $2\,000$ variables de bruit, sélection hors puis dans le pipeline.
4. **Interprétation** : importance par permutation et dépendance partielle de l'instruction de la mère.
5. **Confidentialité** : part d'enfants uniques sur six quasi-identifiants ; publier un comptage avec le mécanisme de Laplace pour $\varepsilon = 1$ et $0{,}1$.
6. **Équité** : audit par milieu ; chercher un seuil rural et un seuil urbain qui donnent le même rappel.

Résumé

- Un projet commence par une question : décision, variables disponibles au moment de prédire, métrique.
- Données d'enquête : codes et étiquettes, codes spéciaux, poids ; on ne lit que les variables utiles.
- Préparation (indicatrices, imputation, standardisation) et modèle dans un même pipeline ; on découpe d'abord.
- Fuites : variable qui contient la réponse, préparation faite avant le découpage. Un score trop beau est suspect.
- Interprétation : importance par permutation, dépendance partielle ; associations, pas causes.
- Confidentialité : quasi-identifiants, conditions d'usage DHS, bruit de Laplace.
- Équité : comparer signalements, rappels et précisions entre groupes ; choisir le critère selon l'usage.

Ce que vous savez faire à la fin du cours

Chapitre	Savoir-faire
1. Fondements	poser un problème d'apprentissage, mesurer une erreur, valider honnêtement
2. Régression	moindres carrés, Ridge et Lasso ; forêt et boosting en régression
3. Classification	k-NN, logistique, arbres ; bagging, forêts, AdaBoost, gradient boosting
4. Non supervisé	ACP et indice de richesse ; k-means, CAH ; observations atypiques
5. De bout en bout	pipeline sans fuite, interprétation, confidentialité, équité

Pour aller plus loin : réseaux de neurones, SVM, théorie de la généralisation… dans un cours de machine learning approfondi. Questions : par message privé ou dans l'onglet Discussions du dépôt `github.com/rdimbamba/ml-cnfsdp`.