CNFSDP

Centre National de Formation en Statistique,
Démographie et Planification
Brazzaville, République du Congo

Introduction au Machine Learning

Chapitre 0

Les outils mathématiques du cours

Matrices, minimisation, probabilités, conditionnement, estimation

Rois Céti DIMBAMBA

Ingénieur statisticien économiste · Actuaire · CV en ligne

Licence 3 · Semestre 5 · UE Informatique IV

Année académique 2026-2027

Polycopié · supports, notebooks et TP : `https://github.com/rdimbamba/ml-cnfsdp`

Objectifs du chapitre

Ce chapitre n'a pas de séance : il se lit chez soi, crayon en main, avant le chapitre 1. Il rassemble *uniquement* les outils mathématiques utilisés dans les chapitres 1 à 5, avec pour chacun l'endroit où il sert.

- Vecteurs et matrices : tableau de données, matrice de covariance, valeurs propres (chapitres 2 et 4).
- Minimiser une fonction : dérivée, gradient, descente de gradient (chapitres 1 à 3).
- Probabilités : espérance, variance, loi normale, loi des grands nombres (chapitre 1).
- Probabilités conditionnelles : formule de Bayes, moyenne conditionnelle (chapitres 1 et 3).
- Estimation : biais, variance, intervalle de confiance, maximum de vraisemblance (chapitres 1 à 3).
- Outils informatiques : installation de Python, VS Code, Git (TP0).

Chaque section se termine par des exercices ; les corrigés sont regroupés à la fin du chapitre.

Table des matières

Notations **4**

1 Vecteurs et matrices **4**

1.1 Vecteurs 4
1.2 Matrices 4
1.3 Le tableau de données et la matrice de covariance 5
1.4 Valeurs propres et vecteurs propres 6

2 Minimiser une fonction **6**

2.1 Fonctions d'une variable 7
2.2 Fonctions de plusieurs variables 7
2.3 La descente de gradient 8

3 Probabilités **8**

3.1 Variables aléatoires, espérance, variance 9
3.2 Covariance, corrélation, indépendance 9
3.3 Lois usuelles 10
3.4 Moyenne d'un échantillon et théorèmes limites 10

4 Probabilités conditionnelles **11**

4.1 Probabilité conditionnelle et formule de Bayes 11
4.2 Moyenne conditionnelle 11

5 Estimation **12**

5.1 Biais, variance, erreur quadratique 12

5.2 Intervalle de confiance d'une proportion 13

5.3 Maximum de vraisemblance 13

6 En Python **14**

6.1 Matrice de covariance et valeurs propres 14

6.2 Droite des moindres carrés et descente de gradient 14

6.3 Loi des grands nombres et théorème central limite 14

6.4 Moyennes conditionnelles 15

7 TP0 – Installation et premiers pas **15**

8 Corrigés des exercices **17**

Notations

Notation	Signification
$x \in \mathbb{R}^d$	vecteur (en colonne) de d nombres $x_1, \dots, x_d$
$A^\top$	transposée de la matrice A (lignes et colonnes échangées)
$\sum_{i=1}^n a_i$	somme $a_1 + a_2 + \cdots + a_n$
$\bar{y} = \frac{1}{n}\sum_{i=1}^n y_i$	moyenne des n nombres $y_1, \dots, y_n$
$\mathbb{P}(A)$	probabilité de l'événement A
$\mathbb{E}[X]$, $\mathrm{Var}(X)$	espérance (moyenne théorique) et variance de X
$\mathbb{P}(A \mid B)$, $\mathbb{E}[Y \mid X = x]$	probabilité de A sachant B ; moyenne de Y sachant $X = x$
$\mathcal{N}(\mu, \sigma^2)$	loi normale de moyenne μ et de variance σ^2
Φ	fonction de répartition de la loi $\mathcal{N}(0,1)$
$\arg\min_c g(c)$	la (ou les) valeur(s) de c où g atteint son minimum

Les variables aléatoires sont notées en majuscules (X, Y), les valeurs observées en minuscules (x, y).

1 Vecteurs et matrices

Un jeu de données est un tableau de nombres. Les vecteurs et les matrices permettent de le manipuler d'un bloc ; ils servent surtout à la régression linéaire (chapitre 2) et à l'ACP (chapitre 4).

1.1 Vecteurs

Définition 1.1 (Vecteur, produit scalaire, norme). Un *vecteur* de $\mathbb{R}^d$ est une liste de d nombres $x = (x_1, \dots, x_d)$, écrite en colonne. Le *produit scalaire* de deux vecteurs x et y est le nombre $\langle x, y\rangle = x_1y_1 + \cdots + x_dy_d$. La *norme* (longueur) de x est $\|x\| = \sqrt{\langle x, x\rangle} = \sqrt{x_1^2 + \cdots + x_d^2}$. Deux vecteurs sont *orthogonaux* si $\langle x, y\rangle = 0$.

Exemple. Pour $x = (1, 2, 2)$ et $y = (2, 0, -1)$: $\langle x, y\rangle = 2 + 0 - 2 = 0$, donc x et y sont orthogonaux, et $\|x\| = \sqrt{1 + 4 + 4} = 3$. Un vecteur de norme 1 est dit *unitaire* : il indique une direction.

1.2 Matrices

Définition 1.2 (Matrice, transposée, produit). Une *matrice* A de taille $n \times d$ est un tableau de nombres à n lignes et d colonnes ; A_{ij} est le nombre en ligne i, colonne j. Sa *transposée* $A^\top$, de taille $d \times n$, échange lignes et colonnes : $(A^\top)_{ij} = A_{ji}$. Si A est de taille $n \times d$

et B de taille $d \times p$, le *produit* AB est la matrice $n \times p$ de coefficients

$$(AB)_{ij} = \sum_{k=1}^{d} A_{ik} B_{kj} \qquad \text{(ligne } i \text{ de } A \text{ « fois » colonne } j \text{ de } B\text{)}.$$

Exemple. $\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 1 \times 5 + 2 \times 6 \\ 3 \times 5 + 4 \times 6 \end{pmatrix} = \begin{pmatrix} 17 \\ 39 \end{pmatrix}$. Attention : en général $AB \neq BA$.

Définition 1.3 (Matrice identité, inverse). La matrice *identité* I_d a des 1 sur la diagonale et des 0 ailleurs : $I_d x = x$. Une matrice carrée A est *inversible* s'il existe une matrice A^{-1} telle que $AA^{-1} = A^{-1}A = I_d$. Le système linéaire $A\beta = b$ a alors une unique solution, $\beta = A^{-1}b$.

Proposition 1.4 (Inverse d'une matrice 2×2)

$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ est inversible si et seulement si $ad - bc \neq 0$, et alors $A^{-1} = \dfrac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$.

Preuve. Un calcul direct donne $\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = (ad - bc)\, I_2$: si $ad - bc \neq 0$, on divise par $ad - bc$. (La réciproque, si $ad - bc = 0$, est admise.) □

1.3 Le tableau de données et la matrice de covariance

Définition 1.5 (Tableau de données, centrage, covariance empirique). On range les observations dans une matrice X de taille $n \times d$: la ligne i décrit l'individu i, la colonne j la variable j. Le *vecteur des moyennes* est $\bar{x} = (\bar{x}_1, \ldots, \bar{x}_d)$, où $\bar{x}_j$ est la moyenne de la colonne j. Le tableau *centré* X_c s'obtient en retranchant à chaque colonne sa moyenne. La *matrice de covariance empirique* est la matrice $d \times d$

$$S = \frac{1}{n} X_c^\top X_c,$$

dont le coefficient S_{jk} est la covariance empirique des variables j et k, et le coefficient diagonal S_{jj} la variance empirique de la variable j.

Exemple. Trois individus, deux variables : $X = \begin{pmatrix} 1 & 2 \\ 2 & 2 \\ 3 & 5 \end{pmatrix}$, de moyennes $\bar{x} = (2, 3)$. Alors $X_c = \begin{pmatrix} -1 & -1 \\ 0 & -1 \\ 1 & 2 \end{pmatrix}$ et $S = \frac{1}{3} \begin{pmatrix} 2 & 3 \\ 3 & 6 \end{pmatrix} = \begin{pmatrix} 2/3 & 1 \\ 1 & 2 \end{pmatrix}$. La covariance positive ($S_{12} = 1$) indique que les deux variables augmentent ensemble.

La matrice S est *symétrique* : $S^\top = S$.

1.4 Valeurs propres et vecteurs propres

Définition 1.6 (Valeur propre, vecteur propre). Soit A une matrice carrée. Un vecteur $u \neq 0$ est un *vecteur propre* de A, associé à la *valeur propre* λ, si $Au = \lambda u$: la matrice ne fait qu'allonger ou raccourcir u, sans changer sa direction.

Théorème 1.7 (Matrices symétriques, admis)

Une matrice symétrique A de taille $d \times d$ possède d valeurs propres réelles $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$, et l'on peut choisir des vecteurs propres associés $u_1, \ldots, u_d$ unitaires et deux à deux orthogonaux. Si A est une matrice de covariance, toutes ses valeurs propres sont positives ou nulles.

Exemple. Pour $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$: $A \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$ et $A \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$. Les valeurs propres sont 3 et 1, de vecteurs propres unitaires $u_1 = \frac{1}{\sqrt{2}}(1,1)$ et $u_2 = \frac{1}{\sqrt{2}}(1,-1)$, qui sont bien orthogonaux.

À quoi cela sert. En ACP (chapitre 4), on cherche la direction u (vecteur unitaire) selon laquelle les individus sont le plus dispersés. La variance des individus projetés sur u vaut $u^\top S u$; elle est maximale pour le premier vecteur propre u_1 de S, et vaut alors λ_1.

Exercices

Exercice 1 (Produit de matrices)

Calculer $A^\top A$ pour $A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$, puis l'inverse de $A^\top A$.

Exercice 2 (Covariance empirique)

Quatre ménages ont pour taille $2, 4, 4, 6$ et pour nombre de pièces $1, 2, 3, 2$. Calculer la matrice de covariance empirique S de ces deux variables, puis la corrélation $S_{12}/\sqrt{S_{11}S_{22}}$.

Exercice 3 (Valeurs propres)

Vérifier que $(1,1)$ et $(1,-1)$ sont des vecteurs propres de $B = \begin{pmatrix} 5 & 3 \\ 3 & 5 \end{pmatrix}$ et donner les valeurs propres associées.

2 Minimiser une fonction

Apprendre, c'est presque toujours chercher les paramètres qui rendent une erreur la plus petite possible. Il faut donc savoir trouver le minimum d'une fonction.

2.1 Fonctions d'une variable

Définition 2.1 (Minimum, minimiseur). On dit qu'une fonction g *atteint son minimum* en c^* si $g(c^*) \leq g(c)$ pour tout c. Le point c^* est alors un *minimiseur* de g, et $g(c^*)$ la *valeur minimale*. On note $c^* \in \arg\min_c g(c)$.

Proposition 2.2 (Rappels, admis)

Soit g une fonction deux fois dérivable sur $\mathbb{R}$.

(i) Si g atteint son minimum en c^*, alors $g'(c^*) = 0$.

(ii) Si $g''(c) \geq 0$ pour tout c (on dit que g est *convexe* : sa courbe est « en cuvette »), alors tout point où g' s'annule est un minimiseur.

(iii) Si $g''(c) > 0$ pour tout c, il y a au plus un minimiseur. (C'est une condition suffisante, pas nécessaire : $c \mapsto c^4$ n'a qu'un minimiseur alors que sa dérivée seconde s'annule en 0.)

Proposition 2.3 (La moyenne minimise les écarts au carré)

Pour des nombres $y_1, \ldots, y_n$, la fonction $g(c) = \sum_{i=1}^n (y_i - c)^2$ atteint son minimum en un unique point, la moyenne $\bar{y}$.

Preuve. $g'(c) = -2\sum_i (y_i - c) = -2(\sum_i y_i - nc)$ s'annule pour $c = \frac{1}{n}\sum_i y_i = \bar{y}$, et $g''(c) = 2n > 0$: on conclut par la proposition 2.2. □

Remarque. Si l'on minimise plutôt $\sum_i |y_i - c|$ (écarts absolus), le minimiseur est une *médiane* des y_i (admis). Ces deux résultats expliquent pourquoi la perte quadratique conduit à prédire des moyennes et la perte absolue des médianes (chapitre 1).

2.2 Fonctions de plusieurs variables

Définition 2.4 (Dérivées partielles, gradient). Pour une fonction $L(a, b)$ de deux variables, la *dérivée partielle* $\frac{\partial L}{\partial a}$ est la dérivée par rapport à a, b étant traité comme une constante (et de même pour b). Le *gradient* est le vecteur $\nabla L = (\frac{\partial L}{\partial a}, \frac{\partial L}{\partial b})$; il indique la direction dans laquelle L augmente le plus vite.

Comme en dimension 1 : si L atteint son minimum en un point, son gradient y est nul ; et si L est convexe (en forme de cuvette), un point où le gradient s'annule est un minimiseur (admis).

Proposition 2.5 (Droite des moindres carrés)

Soient des couples $(x_1, y_1), \ldots, (x_n, y_n)$ avec des x_i non tous égaux. La fonction $L(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$ atteint son minimum en

$$\hat{b} = \frac{s_{xy}}{s_x^2}, \qquad \hat{a} = \bar{y} - \hat{b}\,\bar{x},$$

où $s_x^2 = \frac{1}{n}\sum_i (x_i - \bar{x})^2$ est la variance empirique des x_i et $s_{xy} = \frac{1}{n}\sum_i (x_i - \bar{x})(y_i - \bar{y})$ la covariance empirique.

Preuve. $\frac{\partial L}{\partial a} = -2\sum_i (y_i - a - bx_i) = 0$ donne $a = \bar{y} - b\bar{x}$. En reportant, $\frac{\partial L}{\partial b} = -2\sum_i x_i((y_i - \bar{y}) - b(x_i - \bar{x})) = 0$. Comme $\sum_i \bar{x}((y_i - \bar{y}) - b(x_i - \bar{x})) = 0$, on peut remplacer x_i par $x_i - \bar{x}$,

ce qui donne $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = b \sum_i (x_i - \bar{x})^2$, soit $b = s_{xy}/s_x^2$. La fonction L étant convexe (admis), ce point est le minimiseur. □

Exemple. Pour $x = (1, 2, 3)$ et $y = (2, 2, 5)$: $\bar{x} = 2$, $\bar{y} = 3$, $s_x^2 = \frac{2}{3}$, $s_{xy} = 1$, donc $\hat{b} = 1{,}5$ et $\hat{a} = 0$. La droite $y = 1{,}5\,x$ est celle qui passe « au plus près » des trois points. C'est le point de départ de la régression linéaire du chapitre 2.

2.3 La descente de gradient

Quand on ne sait pas résoudre $\nabla L = 0$ à la main (c'est le cas de la régression logistique, chapitre 3), on s'approche du minimum pas à pas.

Définition 2.6 (Descente de gradient). Partant d'un point θ_0, on répète $\theta_{k+1} = \theta_k - \eta \nabla L(\theta_k)$, où $\eta > 0$ est le *pas* : on fait un petit pas dans la direction où L descend le plus vite.

Proposition 2.7 (Un exemple où tout se calcule)

Pour $L(\theta) = (\theta - 3)^2$, la descente de gradient de pas η vérifie $\theta_k - 3 = (1 - 2\eta)^k (\theta_0 - 3)$. Elle converge vers le minimiseur 3 si et seulement si $0 < \eta < 1$.

Preuve. $L'(\theta) = 2(\theta - 3)$, donc $\theta_{k+1} - 3 = \theta_k - 3 - 2\eta(\theta_k - 3) = (1 - 2\eta)(\theta_k - 3)$, et l'on itère. La suite $(1 - 2\eta)^k$ tend vers 0 si et seulement si $|1 - 2\eta| < 1$, c'est-à-dire $0 < \eta < 1$. □

Lecture. Un pas trop petit avance lentement ; un pas trop grand fait « sauter » par-dessus le minimum et peut diverger. Avec $\theta_0 = 0$ et $\eta = 0{,}25$: $\theta_1 = 1{,}5$, $\theta_2 = 2{,}25$, $\theta_3 = 2{,}625\ldots$ vers 3.

Exercices

Exercice 4 (La meilleure constante)

Les revenus mensuels (en milliers de FCFA) de cinq ménages sont $80, 100, 120, 150, 550$. Quelle constante minimise la somme des écarts au carré ? la somme des écarts absolus ? Commenter l'effet du revenu 550.

Exercice 5 (Droite des moindres carrés)

Calculer la droite des moindres carrés pour les points $(0, 1), (1, 3), (2, 4), (3, 8)$.

Exercice 6 (Choix du pas)

Pour $L(\theta) = 2\theta^2$, écrire la descente de gradient de pas η, puis trouver les valeurs de η pour lesquelles elle converge vers 0.

3 Probabilités

Les données sont vues comme les réalisations de variables aléatoires. C'est ce qui permet de parler d'« erreur moyenne » d'un modèle sur toute une population (chapitre 1).

3.1 Variables aléatoires, espérance, variance

Définition 3.1 (Variable aléatoire, loi). Une *variable aléatoire* X est une quantité dont la valeur dépend du hasard (l'individu tiré au sort, par exemple). Elle est *discrète* si elle prend des valeurs isolées $x_1, x_2, \dots$ avec des probabilités $p_k = \mathbb{P}(X = x_k)$; elle est *continue* si elle a une *densité* $f \geq 0$ telle que $\mathbb{P}(a \leq X \leq b) = \int_a^b f(x)\,dx$.

Définition 3.2 (Espérance, variance, écart-type). L'*espérance* (moyenne théorique) de X est $\mathbb{E}[X] = \sum_k x_k p_k$ dans le cas discret, $\mathbb{E}[X] = \int x f(x)\,dx$ dans le cas continu. La *variance* mesure la dispersion autour de la moyenne : $\mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}[X])^2\big]$; l'*écart-type* est $\sqrt{\mathrm{Var}(X)}$.

Proposition 3.3 (Règles de calcul)

Pour des variables X, Y et des réels a, b :

(i) $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$ (linéarité) ;

(ii) $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ et $\mathrm{Var}(aX + b) = a^2\,\mathrm{Var}(X)$.

Preuve. (i) est admis. (ii) : en développant, $\mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + (\mathbb{E}X)^2$. Puis $aX + b - \mathbb{E}[aX + b] = a(X - \mathbb{E}X)$, dont le carré vaut $a^2(X - \mathbb{E}X)^2$. □

Proposition 3.4 (La meilleure constante est l'espérance)

Pour toute variable Z de variance finie et tout réel c :

$$\mathbb{E}\big[(Z - c)^2\big] = \mathrm{Var}(Z) + \big(\mathbb{E}[Z] - c\big)^2.$$

Donc $c \mapsto \mathbb{E}[(Z - c)^2]$ atteint son minimum en $c = \mathbb{E}[Z]$, et la valeur minimale est $\mathrm{Var}(Z)$.

Preuve. On écrit $Z - c = (Z - \mathbb{E}Z) + (\mathbb{E}Z - c)$ et l'on développe : $\mathbb{E}[(Z - c)^2] = \mathrm{Var}(Z) + 2(\mathbb{E}Z - c)\mathbb{E}[Z - \mathbb{E}Z] + (\mathbb{E}Z - c)^2$, et $\mathbb{E}[Z - \mathbb{E}Z] = 0$. □

C'est la version « population » de la proposition 2.3, et c'est elle qui donne le meilleur prédicteur au chapitre 1.

3.2 Covariance, corrélation, indépendance

Définition 3.5 (Covariance, corrélation). $\mathrm{Cov}(X, Y) = \mathbb{E}\big[(X - \mathbb{E}X)(Y - \mathbb{E}Y)\big]$ et, si les variances sont non nulles, la *corrélation* est $\rho(X, Y) = \dfrac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}$, toujours comprise entre -1 et 1 (admis).

Définition 3.6 (Indépendance). X et Y sont *indépendantes* si connaître la valeur de l'une ne change pas la loi de l'autre : $\mathbb{P}(X \in A,\, Y \in B) = \mathbb{P}(X \in A)\,\mathbb{P}(Y \in B)$ pour tous ensembles A, B.

Proposition 3.7 (admise)

Si X et Y sont indépendantes, alors $\mathrm{Cov}(X, Y) = 0$. Dans tous les cas, $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X, Y)$.

Remarque. Une covariance nulle n'implique pas l'indépendance : la corrélation ne mesure que la liaison *linéaire*.

3.3 Lois usuelles

Loi	Description	$\mathbb{E}[X]$	$\mathrm{Var}(X)$
Bernoulli $\mathcal{B}(p)$	$X=1$ avec probabilité p, 0 sinon	p	$p(1-p)$
Binomiale $\mathcal{B}(n,p)$	nombre de succès en n essais indépendants	np	$np(1-p)$
Uniforme $\mathcal{U}[a,b]$	densité constante $\frac{1}{b-a}$ sur $[a,b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normale $\mathcal{N}(\mu,\sigma^2)$	densité $\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$	μ	σ^2

Si $Z\sim\mathcal{N}(0,1)$, on note $\Phi(t)=\mathbb{P}(Z\le t)$; on retiendra $\mathbb{P}(-1{,}96\le Z\le 1{,}96)\approx 0{,}95$.

3.4 Moyenne d'un échantillon et théorèmes limites

Proposition 3.8 (Espérance et variance d'une moyenne)

Soient $X_1,\dots,X_n$ indépendantes et de même loi, de moyenne μ et de variance σ^2, et $\bar{X}_n=\frac{1}{n}\sum_i X_i$. Alors $\mathbb{E}[\bar{X}_n]=\mu$ et $\mathrm{Var}(\bar{X}_n)=\dfrac{\sigma^2}{n}$.

Preuve. Par linéarité, $\mathbb{E}[\bar{X}_n]=\frac{1}{n}\cdot n\mu=\mu$. Par indépendance (proposition 3.7), les covariances sont nulles et $\mathrm{Var}(\bar{X}_n)=\frac{1}{n^2}\sum_i\mathrm{Var}(X_i)=\frac{n\sigma^2}{n^2}=\frac{\sigma^2}{n}$. □

Théorème 3.9 (Loi des grands nombres, admis)

Sous les mêmes hypothèses, $\bar{X}_n$ se rapproche de μ quand n devient grand : pour tout $\varepsilon>0$, $\mathbb{P}(|\bar{X}_n-\mu|>\varepsilon)\to 0$.

Théorème 3.10 (Théorème central limite, admis)

Pour n grand, $\bar{X}_n$ suit approximativement la loi $\mathcal{N}(\mu,\sigma^2/n)$. En particulier, $\mathbb{P}(|\bar{X}_n-\mu|\le 1{,}96\,\sigma/\sqrt{n})\approx 0{,}95$.

À retenir

Une moyenne calculée sur n observations se trompe typiquement de $\sigma/\sqrt{n}$: pour diviser l'erreur par 2, il faut 4 fois plus de données. C'est ce qui permet d'estimer l'erreur d'un modèle sur un échantillon test (chapitre 1).

Exercices

Exercice 7 (Variable de Bernoulli)

Soit $X\sim\mathcal{B}(p)$. Calculer $\mathbb{E}[X]$, $\mathbb{E}[X^2]$ et retrouver $\mathrm{Var}(X)=p(1-p)$. Pour quelle valeur de p la variance est-elle maximale ?

Exercice 8 (Précision d'un sondage)

On estime la proportion p de ménages équipés d'un réfrigérateur par la proportion observée sur n ménages. En utilisant le théorème central limite et $p(1-p) \le \frac{1}{4}$, quelle taille n garantit une erreur d'au plus 3 points avec probabilité 95 % ?

Exercice 9 (Meilleure constante)

Un dé équilibré donne $Z \in \{1, \dots, 6\}$. Calculer $\mathbb{E}[(Z-c)^2]$ pour $c = 3$ et pour $c = 3{,}5$, et vérifier la proposition 3.4.

4 Probabilités conditionnelles

Prédire Y à partir de X, c'est raisonner « sachant X ». Cette section donne les deux outils du chapitre 1 : la formule de Bayes et la moyenne conditionnelle.

4.1 Probabilité conditionnelle et formule de Bayes

Définition 4.1 (Probabilité conditionnelle). Pour deux événements A et B avec $\mathbb{P}(B) > 0$, la probabilité de A *sachant* B est $\mathbb{P}(A \mid B) = \dfrac{\mathbb{P}(A \text{ et } B)}{\mathbb{P}(B)}$.

Proposition 4.2 (Probabilités totales et formule de Bayes)

Si $B_1, \dots, B_K$ forment une partition (un et un seul se produit), de probabilités non nulles :

$$\mathbb{P}(A) = \sum_{k=1}^{K} \mathbb{P}(A \mid B_k)\,\mathbb{P}(B_k) \qquad \text{et} \qquad \mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \mid B_j)\,\mathbb{P}(B_j)}{\sum_k \mathbb{P}(A \mid B_k)\,\mathbb{P}(B_k)}.$$

Preuve. A est la réunion des événements disjoints « A et B_k », de probabilités $\mathbb{P}(A \mid B_k)\mathbb{P}(B_k)$: on additionne. Puis $\mathbb{P}(B_j \mid A) = \mathbb{P}(A \text{ et } B_j)/\mathbb{P}(A)$, et l'on remplace $\mathbb{P}(A)$ par la première formule. □

Exemple. [Test de dépistage] Une maladie touche 1 % d'une population. Un test est positif chez 95 % des malades et négatif chez 90 % des non-malades. Pour une personne testée positive :

$$\mathbb{P}(M \mid +) = \frac{0{,}95 \times 0{,}01}{0{,}95 \times 0{,}01 + 0{,}10 \times 0{,}99} = \frac{0{,}0095}{0{,}1085} \approx 0{,}088.$$

Moins de 9 % des positifs sont malades : la rareté de la maladie pèse lourd. C'est le raisonnement du classifieur de Bayes (chapitre 1).

4.2 Moyenne conditionnelle

Définition 4.3 (Loi et espérance conditionnelles, cas discret). Si X et Y sont discrètes et $\mathbb{P}(X = x) > 0$, la *loi de* Y *sachant* $X = x$ est donnée par les probabilités $\mathbb{P}(Y = y \mid X = x)$, et

$$\mathbb{E}[Y \mid X = x] = \sum_{y} y\,\mathbb{P}(Y = y \mid X = x)$$

est la *moyenne de Y sachant $X = x$* : la moyenne de Y dans le groupe des individus pour lesquels $X = x$.

Quand Y ne prend que les valeurs 0 et 1, $\mathbb{E}[Y \mid X = x] = \mathbb{P}(Y = 1 \mid X = x)$: une moyenne de 0 et de 1 est une proportion. Le cas continu se définit de la même façon avec des densités ; nous l'admettrons.

Proposition 4.4 (Formule de l'espérance totale)

$\mathbb{E}[Y] = \sum_x \mathbb{E}[Y \mid X = x]\ \mathbb{P}(X = x)$: la moyenne générale est la moyenne pondérée des moyennes de groupes.

Preuve. $\sum_x \mathbb{E}[Y \mid X = x]\mathbb{P}(X = x) = \sum_x \sum_y y\,\mathbb{P}(Y = y \mid X = x)\mathbb{P}(X = x) = \sum_y y \sum_x \mathbb{P}(Y = y, X = x) = \sum_y y\,\mathbb{P}(Y = y) = \mathbb{E}[Y]$. □

Exemple. Parmi les femmes d'une région, 40 % vivent en ville, où la moyenne est de 2,5 enfants, et 60 % en milieu rural, avec 4,5 enfants en moyenne. La moyenne régionale est $0{,}4 \times 2{,}5 + 0{,}6 \times 4{,}5 = 3{,}7$ enfants. Pour prédire le nombre d'enfants d'une femme dont on connaît le milieu, on utilisera 2,5 ou 4,5 plutôt que 3,7 (chapitre 1).

Exercices

Exercice 10 (Prévalence et dépistage)

Reprendre le test de dépistage avec une prévalence de 10 %. Que devient $\mathbb{P}(M \mid +)$? Commenter.

Exercice 11 (Moyennes conditionnelles)

Le couple (X, Y) a la loi suivante.

	$Y = 0$	$Y = 1$	$Y = 2$
$X = 0$	0,2	0,1	0,1
$X = 1$	0,1	0,2	0,3

Calculer $\mathbb{E}[Y \mid X = 0]$ et $\mathbb{E}[Y \mid X = 1]$, puis vérifier la formule de l'espérance totale.

5 Estimation

Un modèle de machine learning est fabriqué à partir d'un échantillon : il en hérite les erreurs d'estimation. Le vocabulaire de cette section (biais, variance) sert dès le chapitre 1.

5.1 Biais, variance, erreur quadratique

Définition 5.1 (Estimateur, biais, erreur quadratique moyenne). On cherche une quantité inconnue θ (une moyenne, une proportion…). Un *estimateur* $\hat{\theta}$ est une formule calculée sur l'échantillon ; il est aléatoire, puisque l'échantillon l'est. Son *biais* est $\mathbb{E}[\hat{\theta}] - \theta$ (l'erreur systématique), et son *erreur quadratique moyenne* est $\mathrm{EQM}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$.

Proposition 5.2 (Décomposition biais-variance)

$\mathrm{EQM}(\hat{\theta}) = \left(\mathbb{E}[\hat{\theta}] - \theta\right)^2 + \mathrm{Var}(\hat{\theta})$.

Preuve. C'est la proposition 3.4 appliquée à $Z = \hat{\theta}$ et $c = \theta$. □

Lecture. Une erreur vient soit d'un tir mal centré (biais), soit d'un tir dispersé (variance). Au chapitre 1, le même découpage explique le sur-apprentissage : un modèle trop simple est biaisé, un modèle trop complexe a une forte variance.

Exemple. [Moyenne empirique] D'après la proposition 3.8, $\bar{X}_n$ est sans biais pour μ et $\mathrm{EQM}(\bar{X}_n) = \sigma^2/n$.

5.2 Intervalle de confiance d'une proportion

Proposition 5.3 (admise, conséquence du théorème central limite)

Si $\hat{p}$ est la proportion observée d'un caractère sur n individus tirés au hasard, alors pour n grand,

$$\left[\hat{p} - 1{,}96\sqrt{\tfrac{\hat{p}(1-\hat{p})}{n}} \;;\; \hat{p} + 1{,}96\sqrt{\tfrac{\hat{p}(1-\hat{p})}{n}}\right]$$

contient la vraie proportion p avec une probabilité d'environ 95 %.

Au chapitre 1, $\hat{p}$ sera le taux d'erreur d'un classifieur mesuré sur un échantillon test.

5.3 Maximum de vraisemblance

Définition 5.4 (Vraisemblance, estimateur du maximum de vraisemblance). Si les observations $x_1, \dots, x_n$ sont indépendantes, de loi dépendant d'un paramètre θ (probabilité ou densité p_θ), la *vraisemblance* est $\mathcal{L}(\theta) = p_\theta(x_1) \times \cdots \times p_\theta(x_n)$: la probabilité d'avoir observé ces données si le paramètre vaut θ. L'*estimateur du maximum de vraisemblance* est la valeur de θ qui rend $\mathcal{L}(\theta)$, ou de façon équivalente $\log \mathcal{L}(\theta)$, la plus grande.

Exemple. [Proportion] Pour des observations $x_i \in \{0, 1\}$ de loi $\mathcal{B}(\theta)$, avec $s = \sum_i x_i$ succès $(0 < s < n)$: $\log \mathcal{L}(\theta) = s \log \theta + (n - s) \log(1 - \theta)$, de dérivée $\frac{s}{\theta} - \frac{n-s}{1-\theta}$, nulle pour $\hat{\theta} = s/n$: la proportion observée.

Remarque. Maximiser la vraisemblance revient à minimiser $-\log \mathcal{L}(\theta)$, une somme d'erreurs sur les observations. La régression logistique du chapitre 3 est construite ainsi.

Exercices

Exercice 12 (Un biais qui paie)

Soient $X_1, \dots, X_n$ indépendantes, de moyenne $\mu \neq 0$ et de variance σ^2. Pour $c \in \mathbb{R}$, on estime μ par $c\,\bar{X}_n$. Calculer le biais, la variance, puis l'erreur quadratique moyenne de $c\,\bar{X}_n$. Montrer qu'elle est minimale pour $c^* = \dfrac{\mu^2}{\mu^2 + \sigma^2/n} < 1$. Pourquoi ce c^* n'est-il pas directement utilisable ?

Exercice 13 (Intervalle de confiance)

Un classifieur se trompe sur 45 des 300 individus d'un échantillon test. Donner un intervalle de confiance à 95 % pour son taux d'erreur.

6 En Python

Chaque outil de ce chapitre se vérifie en quelques lignes de NumPy. Les sorties indiquées en commentaire sont celles obtenues ; ces programmes sont regroupés dans le notebook `TP0.ipynb`.

6.1 Matrice de covariance et valeurs propres

```python
import numpy as np

# Matrice de covariance et valeurs propres (sections 1)
X = np.array([[1, 2], [2, 2], [3, 5]])        # 3 individus, 2 variables
Xc = X - X.mean(axis=0)                        # tableau centré
S = Xc.T @ Xc / len(X)                         # covariance empirique
print(S.round(3))                              # [[0.667 1.] [1. 2.]]
lam, U = np.linalg.eigh(S)                     # valeurs propres croissantes
print(lam.round(4))                            # [0.1315 2.5352]
print(U[:, -1].round(3))                       # premier axe de l'ACP
```

On retrouve la matrice S de l'exemple de la section 1. Le vecteur propre de la plus grande valeur propre donne la direction de plus grande dispersion des trois points : c'est le premier axe de l'ACP.

6.2 Droite des moindres carrés et descente de gradient

```python
import numpy as np

# Droite des moindres carrés (section 2)
x = np.array([1, 2, 3]); y = np.array([2, 2, 5])
b = np.mean((x - x.mean()) * (y - y.mean())) / np.var(x)   # s_xy / s_x^2
a = y.mean() - b * x.mean()
print(a, b)                                    # 0.0 1.5
print(np.polyfit(x, y, deg=1).round(4))        # [1.5 0.] : même droite

# Descente de gradient sur L(θ) = (θ - 3)^2
theta, eta = 0.0, 0.25
for k in range(6):
    theta = theta - eta * 2 * (theta - 3)
    print(round(theta, 4), end=" ")            # 1.5 2.25 2.625 2.8125 ...
```

Les formules de la proposition 2.5 donnent la même droite que `np.polyfit`, et la descente de gradient s'approche de 3 comme prévu par la proposition 2.7.

6.3 Loi des grands nombres et théorème central limite

```python
import numpy as np
rng = np.random.default_rng(2)

# Loi des grands nombres et TCL (section 3)
p, n, R = 0.3, 400, 20_000                     # R sondages de n personnes
props = rng.binomial(n, p, size=R) / n         # R proportions observées
print(props.mean().round(4), props.var().round(6), p * (1 - p) / n)
```

```python
ecart = 1.96 * np.sqrt(p * (1 - p) / n)
print(np.mean(np.abs(props - p) <= ecart).round(3))   # proche de 0.95
```

La variance des proportions observées vaut bien $p(1-p)/n$, et l'écart à p reste sous $1{,}96\sqrt{p(1-p)/n}$ dans environ 95 % des sondages simulés (94,3 % ici).

6.4 Moyennes conditionnelles

```python
import numpy as np, pandas as pd
rng = np.random.default_rng(3)

# Moyennes conditionnelles par groupe (section 4)
n = 10_000
milieu = rng.choice(["urbain", "rural"], size=n, p=[0.4, 0.6])
enfants = np.where(milieu == "urbain", rng.poisson(2.5, n), rng.poisson(4.5, n))
df = pd.DataFrame({"milieu": milieu, "enfants": enfants})

print(df.groupby("milieu")["enfants"].mean().round(2))   # ≈ 4.5 et 2.5
part = df["milieu"].value_counts(normalize=True)
moy = df.groupby("milieu")["enfants"].mean()
print(round((part * moy).sum(), 4), round(df["enfants"].mean(), 4))  # espérance totale
```

Les moyennes par groupe estiment $\mathbb{E}[Y \mid X = x]$, et leur moyenne pondérée redonne la moyenne générale (proposition 4.4).

7 TP0 – Installation et premiers pas

TP0 – à faire chez soi avant le chapitre 1 environ 1 h 30 ·
`github.com/rdimbamba/ml-cnfsdp`

Objectif : arriver au premier cours avec un environnement Python fonctionnel, le dépôt du cours sur sa machine, et le notebook `TP0.ipynb` exécuté. En cas de blocage, Google Colab permet de faire tous les TP dans un navigateur, sans rien installer (étape 6).

Étape 1 – Python avec Miniconda

Télécharger l'installateur Miniconda pour votre système depuis le site officiel d'Anaconda (`https://www.anaconda.com/docs/getting-started/miniconda/install`) et l'installer avec les options par défaut. Sous Windows, ouvrir ensuite le programme *Anaconda Prompt* ; sous macOS ou Linux, un terminal. Vérifier :

```
conda --version
```

Étape 2 – Environnement du cours

Créer un environnement isolé contenant les bibliothèques du cours, puis l'activer :

```
conda create -n ml-cnfsdp -c conda-forge python=3.12 numpy pandas matplotlib scikit-
    ↪ learn jupyter ipykernel pyreadstat
conda activate ml-cnfsdp
python -c "import numpy, sklearn; print(numpy.__version__, sklearn.__version__)"
```

La bibliothèque `pyreadstat` servira à lire les fichiers SPSS des enquêtes DHS au chapitre 5.

Étape 3 – VS Code

Installer Visual Studio Code (`https://code.visualstudio.com`), puis, dans l'onglet *Extensions*, les extensions *Python* et *Jupyter* publiées par Microsoft. Dans VS Code, `Ctrl+Maj+P`, puis *Python : Select Interpreter*, et choisir l'environnement `ml-cnfsdp`.

Étape 4 – Git et Git Bash

Installer Git (`https://git-scm.com`) ; sous Windows, l'installation fournit le terminal *Git Bash*. Puis, une seule fois :

```
git config --global user.name "Prénom Nom"
git config --global user.email "adresse@exemple.com"
```

Étape 5 – GitHub et dépôt du cours

Créer un compte gratuit sur `https://github.com`. Dans Git Bash, cloner le dépôt du cours et l'ouvrir dans VS Code :

```
git clone https://github.com/rdimbamba/ml-cnfsdp.git
cd ml-cnfsdp
code .
```

Pour récupérer les nouveaux supports au fil du semestre : `git pull` depuis ce dossier.

Étape 6 – Exécuter le notebook

Ouvrir `notebooks/TP0.ipynb` dans VS Code et exécuter toutes les cellules (*Run All*). Sans installation locale : ouvrir `https://colab.research.google.com`, onglet *GitHub*, saisir `rdimbamba/ml-cnfsdp`, puis choisir `TP0.ipynb` ; ou cliquer sur le bouton *Open in Colab* de la page du cours.

Liste de vérification

- ☐ `conda activate ml-cnfsdp` fonctionne et `import sklearn` ne renvoie pas d'erreur.
- ☐ VS Code exécute une cellule de notebook avec l'environnement `ml-cnfsdp`.
- ☐ `git --version` répond, et le dossier `ml-cnfsdp` est cloné.
- ☐ Les quatre programmes de la section 6 donnent les mêmes sorties.

Exercices du TP0

Ils sont posés dans le notebook ; chacun vérifie numériquement un résultat du chapitre.

1. *Matrices.* Calculer avec NumPy $A^\top A$ et son inverse pour la matrice de l'exercice 1, et comparer avec votre calcul à la main.
2. *Bayes par simulation.* Simuler un million de personnes avec la prévalence et le test de l'exemple de la section 4, et estimer $\mathbb{P}(M \mid +)$.
3. *Choix du pas.* Pour $L(\theta) = 2\theta^2$, lancer 50 pas de descente de gradient depuis $\theta_0 = 1$ avec $\eta = 0{,}4$, puis $\eta = 0{,}6$; comparer avec l'exercice 6.
4. *Un biais qui paie.* Pour $\mu = 1$, $\sigma = 3$, $n = 10$, estimer par simulation l'erreur quadratique de $c\,\bar{X}_n$ pour $c \in [0{,}5; 1{,}2]$ et comparer le minimum à la valeur c^* de l'exercice 12.

8 Corrigés des exercices

Corrigé. Exercice 1. $A^\top A = \begin{pmatrix}1&1&1\\0&1&2\end{pmatrix}\begin{pmatrix}1&0\\1&1\\1&2\end{pmatrix} = \begin{pmatrix}3&3\\3&5\end{pmatrix}$. Son déterminant vaut $3\times 5 - 3\times 3 = 6 \neq 0$, donc $(A^\top A)^{-1} = \frac{1}{6}\begin{pmatrix}5&-3\\-3&3\end{pmatrix}$.

Corrigé. Exercice 2. Moyennes : 4 personnes et 2 pièces. Écarts : $(-2,0,0,2)$ et $(-1,0,1,0)$. $S_{11} = \frac{4+0+0+4}{4} = 2$, $S_{22} = \frac{1+0+1+0}{4} = 0{,}5$, $S_{12} = \frac{2+0+0+0}{4} = 0{,}5$, donc $S = \begin{pmatrix}2&0{,}5\\0{,}5&0{,}5\end{pmatrix}$ et la corrélation vaut $\frac{0{,}5}{\sqrt{2\times 0{,}5}} = 0{,}5$.

Corrigé. Exercice 3. $B\begin{pmatrix}1\\1\end{pmatrix} = \begin{pmatrix}8\\8\end{pmatrix} = 8\begin{pmatrix}1\\1\end{pmatrix}$ et $B\begin{pmatrix}1\\-1\end{pmatrix} = \begin{pmatrix}2\\-2\end{pmatrix} = 2\begin{pmatrix}1\\-1\end{pmatrix}$: valeurs propres 8 et 2.

Corrigé. Exercice 4. La somme des écarts au carré est minimale pour la moyenne, $\frac{80+100+120+150+550}{5} = 200$; la somme des écarts absolus pour la médiane, 120. Le revenu 550 tire la moyenne vers le haut : quatre ménages sur cinq gagnent moins que la moyenne. La médiane résiste aux valeurs extrêmes.

Corrigé. Exercice 5. $\bar{x} = 1{,}5$, $\bar{y} = 4$; écarts $(-1{,}5;-0{,}5;0{,}5;1{,}5)$ et $(-3,-1,0,4)$. $s_{xy} = \frac{4{,}5+0{,}5+0+6}{4} = 2{,}75$ et $s_x^2 = \frac{2{,}25+0{,}25+0{,}25+2{,}25}{4} = 1{,}25$, d'où $\hat{b} = 2{,}2$ et $\hat{a} = 4 - 2{,}2\times 1{,}5 = 0{,}7$: la droite est $y = 0{,}7 + 2{,}2\,x$.

Corrigé. Exercice 6. $L'(\theta) = 4\theta$, donc $\theta_{k+1} = \theta_k - 4\eta\theta_k = (1-4\eta)\theta_k$ et $\theta_k = (1-4\eta)^k\theta_0$. La descente converge vers 0 si et seulement si $|1-4\eta| < 1$, c'est-à-dire $0 < \eta < \frac{1}{2}$.

Corrigé. Exercice 7. $\mathbb{E}[X] = 1\times p + 0\times(1-p) = p$ et $\mathbb{E}[X^2] = p$ (car $X^2 = X$), donc $\mathrm{Var}(X) = p - p^2 = p(1-p)$, maximale pour $p = \frac{1}{2}$ où elle vaut $\frac{1}{4}$.

Corrigé. Exercice 8. Il faut $1{,}96\sqrt{p(1-p)/n} \le 0{,}03$. Comme $p(1-p) \le \frac{1}{4}$, il suffit que $1{,}96\times\frac{1}{2\sqrt{n}} \le 0{,}03$, soit $n \ge \left(\frac{1{,}96}{0{,}06}\right)^2 \approx 1\,067{,}1$: $n = 1\,068$ ménages.

Corrigé. Exercice 9. $\mathbb{E}[Z] = 3{,}5$ et $\mathrm{Var}(Z) = \frac{35}{12} \approx 2{,}917$. Pour $c = 3$: $\mathbb{E}[(Z-3)^2] = \frac{4+1+0+1+4+9}{6} = \frac{19}{6} \approx 3{,}167 = \frac{35}{12} + (3{,}5-3)^2$. Pour $c = 3{,}5$: on obtient $\mathrm{Var}(Z)$, la valeur minimale.

Corrigé. Exercice 10. $\mathbb{P}(+) = 0{,}95\times 0{,}10 + 0{,}10\times 0{,}90 = 0{,}185$ et $\mathbb{P}(M \mid +) = \frac{0{,}095}{0{,}185} \approx 0{,}51$. Avec le même test, un résultat positif passe de 9 % à 51 % de chances d'être un vrai malade : la prévalence compte autant que la qualité du test.

Corrigé. Exercice 11. $\mathbb{P}(X=0)=0{,}4$ et $\mathbb{P}(X=1)=0{,}6$. $\mathbb{E}[Y \mid X=0]=\frac{0\times0{,}2+1\times0{,}1+2\times0{,}1}{0{,}4}=0{,}75$ et $\mathbb{E}[Y \mid X=1]=\frac{0\times0{,}1+1\times0{,}2+2\times0{,}3}{0{,}6}=\frac{4}{3}$. Espérance totale : $0{,}4\times0{,}75+0{,}6\times\frac{4}{3}=1{,}1$, et directement $\mathbb{E}[Y]=1\times0{,}3+2\times0{,}4=1{,}1$.

Corrigé. Exercice 12. Biais : $c\mu-\mu=(c-1)\mu$; variance : $c^2\sigma^2/n$. Par la proposition 5.2, $\mathrm{EQM}(c)=(1-c)^2\mu^2+c^2\frac{\sigma^2}{n}$, dont la dérivée $-2(1-c)\mu^2+2c\frac{\sigma^2}{n}$ s'annule en $c^*=\frac{\mu^2}{\mu^2+\sigma^2/n}<1$ (minimum, car la dérivée seconde est positive). Accepter un peu de biais réduit davantage la variance : c'est l'idée de la régression ridge (chapitre 2). Mais c^* dépend de μ et σ, inconnus : en pratique, on règle ce type de paramètre sur les données, par validation croisée (chapitre 1).

Corrigé. Exercice 13. $\hat{p}=\frac{45}{300}=0{,}15$ et $1{,}96\sqrt{\frac{0{,}15\times0{,}85}{300}}\approx0{,}040$: le taux d'erreur est compris entre 11 % et 19 % avec une confiance d'environ 95 %.