CNFSDP

Centre National de Formation en Statistique,
Démographie et Planification
Brazzaville, République du Congo

Introduction au Machine Learning

Guide du projet de groupe

Organisation, accès aux données DHS, charte d'utilisation

Rois Céti DIMBAMBA

Ingénieur statisticien économiste · Actuaire · CV en ligne

Licence 3 · Semestre 5 · UE Informatique IV

Année académique 2026-2027

Supports, notebooks et TP : `https://github.com/rdimbamba/ml-cnfsdp`

Objet de ce guide

Ce guide accompagne le chapitre 5 (projet de bout en bout). Il rassemble ce qu'il faut pour démarrer le projet : la répartition des groupes, le calendrier, l'accès aux données DHS par l'autorisation de classe, la charte d'utilisation à signer, et, pour plus tard, la procédure pour obtenir les données en son nom.

1 Organisation

- **Groupes** : 36 étudiants, 9 groupes de 4 ; une variante différente par groupe, attribuée en salle.
- **Données** : Enquête démographique et de santé du Congo 2011-2012 (EDS, programme DHS), fichiers originaux.
- **Travail demandé** : sur un même thème, une question de prédiction (chapitres 1 à 3) et une analyse non supervisée des mêmes données (ACP ou typologie, chapitre 4), suivies d'une courte discussion des limites.
- **Livrables** : un rapport de 10 pages et un notebook ; une soutenance de 15 minutes où chacun des quatre membres présente une partie. Répartition indicative des 10 pages :
  - introduction, données et préparation (question, population, construction de la cible, valeurs manquantes) : environ 2 pages ;
  - prédiction (chapitres 1 à 3 : au moins trois modèles comparés, validation croisée, métriques adaptées) : environ 4,5 pages ;
  - analyse non supervisée (ACP ou typologie, chapitre 4) : environ 2,5 pages ;
  - conclusion et limites : environ 1 page.
- **Calendrier** : remise du rapport et soutenances **fin novembre 2026**, deux à trois semaines après le chapitre 5 ; dates exactes annoncées en salle.
- **Évaluation du cours** : examen sur table 40 %, rapport et notebook 40 %, soutenance 20 %.

gr.	thème	fichier	cible à prédire	variante
1	richesse	`HR`	ménage dans les 40 % les plus pauvres	indice national (ACP), comparé à `hv271`
2	richesse	`HR`	ménage dans les 40 % les plus pauvres	indices urbain et rural séparés
3	vaccination	`KR`	vaccination complète (`h2` à `h9`)	enfants de 12 à 23 mois
4	vaccination	`KR`	abandon : DTC1 reçu, DTC3 non	enfants de 12 à 23 mois
5	vaccination	`KR`	rougeole (`h9`)	enfants de 12 à 23 mois
6	nutrition	`KR`	retard de croissance (`hw70` < -200)	enfants de moins de 5 ans
7	nutrition	`KR`	insuffisance pondérale (`hw71` < -200)	enfants de moins de 5 ans
8	femme	`IR`	contraception moderne (`v313` $= 3$)	femmes en union
9	femme	`IR`	besoins non satisfaits en contraception	femmes en union

Codes à vérifier dans le dictionnaire de l'enquête (par exemple, exclure les codes ≥ 9996 de `hw70` et `hw71`). Les groupes 1 et 2 prédisent la pauvreté avec des variables qui ne servent pas à construire l'indice (taille du

ménage, chef de ménage, région). Chaque sujet est détaillé dans une fiche de démarrage (section 2).

2 Fiches de démarrage

Chaque fiche donne le fichier et la population à retenir, la définition exacte de la cible, des variables explicatives suggérées, les variables à écarter (fuites d'information : variables qui contiennent déjà la réponse), un taux de contrôle et une piste pour le volet non supervisé. **Le taux de contrôle** est la proportion pondérée de la cible calculée sur le fichier (poids `v005`/10^6, ou `hv005`/10^6 pour les ménages) ; votre cible, une fois construite, doit le retrouver à quelques dixièmes de point près, et il est à rapprocher du rapport final de l'EDSC-II 2011-2012. Les listes de variables sont des points de départ, à compléter après lecture du dictionnaire.

Groupe 1 – Richesse : indice national

Fichier, population : `HR`, tous les ménages (11 632).
Cible : `pauvre` = 1 si `hv270` $\in \{1, 2\}$ (deux quintiles les plus bas), 0 sinon.
Explicatives suggérées : taille du ménage `hv009`, enfants de moins de 5 ans `hv014`, femmes et hommes éligibles `hv010`, `hv011`, sexe et âge du chef `hv219`, `hv220`, milieu `hv025`, région `hv024` ; facultatif : instruction du chef (fichier `PR`, `hv106` de la ligne `hv218`).
À écarter : biens et logement (`hv201` à `hv215`, `hv221`, `hv226`, `hv243*`, `hv246*`, `hv247`), `hv271`.
Taux de contrôle : 40,8 % des ménages (39,7 % de la population, 40 % par construction).
Non supervisé : ACP nationale sur les biens et le logement ; le premier axe fournit un indice, à comparer à `hv271` (corrélation) et aux quintiles `hv270`.

Groupe 2 – Richesse : indices urbain et rural

Fichier, population : `HR`, ménages urbains (3 150) et ruraux (8 482), traités séparément.
Cible : comme le groupe 1 (`hv270` $\in \{1, 2\}$).
Explicatives suggérées : celles du groupe 1 ; comparer un modèle unique avec `hv025` et deux modèles séparés.
À écarter : comme le groupe 1.
Taux de contrôle : 13,9 % de la population urbaine et 86,5 % de la population rurale appartiennent aux 40 % les plus pauvres.
Non supervisé : deux ACP, l'une sur les ménages urbains, l'autre sur les ruraux ; comparer les variables qui portent le premier axe dans chaque milieu, puis le classement des ménages avec l'indice national `hv271`.

Groupe 3 – Vaccination complète

Fichier, population : `KR`, enfants vivants (`b5` = 1) âgés de 12 à 23 mois (âge en mois = `v008` − `b3`) : 1 884 enfants.
Cible : 1 si `h2` (BCG), `h3`, `h5`, `h7` (DTC 1 à 3), `h4`, `h6`, `h8` (polio 1 à 3) et `h9` (rougeole) valent tous 1, 2 ou 3 (vaccin reçu, sur carte ou déclaré).
Explicatives suggérées : sexe `b4`, rang de naissance `bord`, âge de la mère `v012`, instruction `v106`, quintile `v190`, milieu `v025`, région `v024`, visites prénatales `m14`, lieu d'accouchement `m15`, exposition aux médias `v157` à `v159`, taille du ménage `v136`.
À écarter : toutes les variables de vaccination `h0` à `h10` et la carte de vaccination `h1`.
Taux de contrôle : 38,1 %.
Non supervisé : typologie (k-means ou CAH) des enfants et de leurs mères sur les variables explicatives, puis taux de vaccination complète par classe.

Groupe 4 – Abandon entre DTC1 et DTC3

Fichier, population : `KR`, enfants vivants de 12 à 23 mois ayant reçu le DTC1 (`h3` $\in \{1, 2, 3\}$) : 1 290 enfants.
Cible : 1 si le DTC3 n'a pas été reçu (`h7` $\notin \{1, 2, 3\}$).
Explicatives suggérées : celles du groupe 3.
À écarter : comme le groupe 3.
Taux de contrôle : 25,0 % d'abandon (DTC1 : 74,5 % ; DTC3 : 56,3 % des 12–23 mois).
Non supervisé : typologie des enfants ayant commencé le calendrier vaccinal ; taux d'abandon par classe.

Groupe 5 – Vaccination contre la rougeole

Fichier, population : `KR`, enfants vivants de 12 à 23 mois : 1 884 enfants.
Cible : 1 si `h9` $\in \{1, 2, 3\}$.
Explicatives suggérées : celles du groupe 3 ; l'âge exact de l'enfant en mois compte ici (vaccin administré vers 9 mois).
À écarter : comme le groupe 3 (les autres vaccins sont très liés à la cible).
Taux de contrôle : 74,9 %.
Non supervisé : ACP des caractéristiques de la mère et du ménage ; positionner les enfants non vaccinés sur le premier plan factoriel.

Groupe 6 – Retard de croissance

Fichier, population : `KR`, enfants vivants mesurés, `hw70` < 9996 : 4 475 enfants.
Cible : 1 si `hw70` < -200 (score taille-pour-âge inférieur à -2 écarts-types).
Explicatives suggérées : âge en mois `hw1`, sexe `b4`, rang `bord`, intervalle avec la naissance précédente `b11`, taille à la naissance perçue `m18`, taille et IMC de la mère `v438`, `v445` (codes spéciaux à exclure), instruction `v106`, quintile `v190`, milieu `v025`, région `v024`, diarrhée récente `h11`, eau `v113`, toilettes `v116`.
À écarter : les autres indices anthropométriques `hw71`, `hw72`, et le poids et la taille de l'enfant `hw2`, `hw3` (ils servent à calculer la cible).
Taux de contrôle : 23,1 %.
Non supervisé : ACP des caractéristiques de l'enfant, de la mère et du ménage ; lecture du premier plan et position des enfants en retard de croissance.

Groupe 7 – Insuffisance pondérale

Fichier, population : `KR`, enfants vivants mesurés, `hw71` < 9996 : 4 475 enfants.
Cible : 1 si `hw71` < -200 (score poids-pour-âge inférieur à -2 écarts-types).
Explicatives suggérées : celles du groupe 6.
À écarter : `hw70`, `hw72`, `hw2`, `hw3`.
Taux de contrôle : 11,1 %.
Non supervisé : typologie (k-means ou CAH) des couples mère–enfant ; taux d'insuffisance pondérale par classe.

Groupe 8 – Contraception moderne

Fichier, population : `IR`, femmes actuellement en union (`v502` $= 1$) : 6 750 femmes.
Cible : 1 si `v313` $= 3$ (méthode moderne).
Explicatives suggérées : âge `v012`, instruction `v106`, quintile `v190`, milieu `v025`, région `v024`, enfants nés vivants `v201`, enfants vivants `v218`, religion `v130`, exposition aux médias `v157` à `v159`, travail `v714`, âge à la première union `v511`, décision sur sa propre santé `v743a`.
À écarter : méthode utilisée et utilisation passée ou prévue (`v312`, `v361` à `v364`), besoins non satisfaits `v626a`.
Taux de contrôle : 20,0 %.
Non supervisé : typologie des femmes en union sur les variables explicatives ; taux de contraception moderne par classe.

Groupe 9 – Besoins non satisfaits en contraception

Fichier, population : `IR`, femmes actuellement en union : 6 750 femmes.
Cible : 1 si `v626a` $\in \{1, 2\}$ (besoin non satisfait pour espacer ou pour limiter).
Explicatives suggérées : celles du groupe 8.
À écarter : les composantes de l'indicateur, `v312`, `v313`, `v364`, désir d'enfants `v602`, `v605`, grossesse actuelle `v213`, aménorrhée et abstinence `v405`, `v406`.
Taux de contrôle : 18,4 %.
Non supervisé : ACP des caractéristiques des femmes ; position des femmes ayant un besoin non satisfait sur le premier plan factoriel.

3 Accès aux données pour le cours : l'autorisation de classe

À retenir

Pour ce cours, l'enseignant demande au programme DHS une **autorisation pour toute la classe**. Les étudiants n'ont pas de compte à créer : les fichiers leur sont remis par l'enseignant, pour le seul projet du cours, dans les conditions fixées par l'accord écrit de DHS. Ce qui est rendu, c'est le code et le rapport, jamais les données.

La procédure suivie par l'enseignant

Elle est décrite ici pour qu'un futur enseignant, ou un étudiant devenu enseignant, puisse la reprendre.

1. **Créer son compte** d'utilisateur DHS (voir la section 4 pour les précautions d'inscription).
2. **Repérer l'option « Instructors »** : sur la page de création d'un projet, DHS indique que les enseignants peuvent faire autoriser leur classe sans inscription individuelle des étudiants, sur demande par courriel.
3. **Écrire à** `archive@dhsprogram.com` depuis l'adresse du compte, en précisant : l'établissement et le cours ; l'effectif (avec la liste nominative des étudiants si DHS la demande) ; l'enquête et les fichiers (Congo DHS 2011-12, fichiers ménages `HR`, femmes `IR`, enfants `KR`, format Stata ou SPSS) ; l'usage (projets de groupe encadrés) ; les dates (octobre à décembre 2026) ; les règles imposées aux étudiants.
4. **Attendre la réponse** de DHS, qui fixe les conditions de l'autorisation, puis télécharger les fichiers depuis le compte de l'enseignant.
5. **Remettre les fichiers** aux seuls étudiants inscrits, par un canal privé (clé USB en salle ou dossier partagé restreint à la classe), après signature de la charte ci-dessous. Jamais de dépôt public.
6. **Clore** : à la fin du cours, rappeler aux étudiants de supprimer leurs copies, sauf autre disposition de l'accord DHS.

Charte d'utilisation des données DHS – à signer par chaque étudiant

Je soussigné(e) ..... , étudiant(e) du cours *Introduction au Machine Learning* (CNFSDP, 2026-2027), reçois de l'enseignant les fichiers de l'Enquête démographique et de santé du Congo 2011-2012, mis à disposition par le programme DHS au titre d'une autorisation de classe. Je m'engage à :

— n'utiliser ces données que pour le projet de groupe du cours ;

— ne les transmettre à personne, pas même à un autre étudiant ou à un autre groupe : chacun reçoit sa copie de l'enseignant ;

— ne jamais les déposer sur Internet (GitHub, messagerie, réseaux sociaux, dossier partagé public) ;

— ne tenter d'identifier aucune personne ni aucun ménage ;

— supprimer mes copies à la fin du cours.

Date : _____ Signature : _____

4 Pour plus tard : faire sa propre demande DHS

Après le cours, pour un mémoire, un stage ou une recherche, chacun peut obtenir les données DHS *en son nom*. L'autorisation de classe ne couvre que le projet du cours.

1. **Créer son compte** : `https://dhsprogram.com/data/new-user-registration.cfm`
   — sur un **ordinateur** (le formulaire ne fonctionne pas sur téléphone) ;
   — **sans traduction automatique** : si le navigateur propose de traduire la page, refuser (« Afficher l'original ») et recharger la page ;
   — **tous les champs en anglais et sans accents**, par exemple *Centre National de Formation en Statistique, Demographie et Planification*, écrit en entier ;
   — pays de résidence : *Congo* (et non *Congo Democratic Republic*) ; téléphone avec l'indicatif `+242` ; mot de passe de 8 à 15 caractères ;
   — une adresse électronique que vous consultez : elle sert d'identifiant, et l'accord arrive par courriel.
2. **Créer un projet** (*Create New Project*) : titre, co-chercheurs éventuels (facultatif), description de l'analyse prévue (modèle ci-dessous, à adapter).
3. **Choisir le pays et l'enquête**, puis les jeux de données d'enquête (*survey datasets*) ; les données GPS ou biomarqueurs demandent des engagements supplémentaires.
4. **Attendre l'accord**, en général sous 24 à 48 heures ouvrées, puis télécharger. Instructions officielles : `https://dhsprogram.com/data/Access-Instructions.cfm`

Si la connexion échoue sans message d'erreur. Repartir de la page `https://dhsprogram.com/data/dataset_admin/login_main.cfm` sans rien ajouter à l'adresse ; effacer les cookies du site `dhsprogram.com` ou ouvrir une fenêtre de navigation privée ; désactiver la traduction ; vérifier les majuscules du mot de passe ; à défaut, utiliser « mot de passe oublié » ou écrire à `archive@dhsprogram.com`.

Modèle de description de projet (en anglais, sans accents ; remplacer les crochets)

Project Title :
[Short title, for example : Determinants of child vaccination in the Republic of the Congo]

Description :
I am [a master student / a statistician] at [full name of the institution], [city, country]. I will use the [survey, for example Congo DHS 2011-12] [files, for example household, women and children recode files] to study [research question]. Methods : [for example logistic regression, random forests, principal component analysis]. The results will be presented in [a thesis / a report / an article]. The data will be kept on my own computer and will not be shared or published.

5 Après réception des fichiers : premiers pas

Ranger les fichiers dans un dossier `donnees/`. Le fichier `.gitignore` du projet doit contenir au moins les lignes suivantes, pour que les données ne partent jamais sur GitHub :

```
donnees/
*.DTA
*.dta
*.SAV
*.sav
```

On ne lit que les variables utiles, en gardant les codes, comme au TP5 :

```
import numpy as np, pandas as pd
fichier = "donnees/CGKR61FL.DTA"                    # fichier enfants (KR), à adapter
with pd.io.stata.StataReader(fichier) as lecteur:
    etiquettes = lecteur.value_labels()             # codes -> libellés
    libelles = lecteur.variable_labels()            # nom long de chaque variable
colonnes = ["v005", "v024", "v025", "v106", "v190", "b4", "bord", "h2", "h3", "h9"]
df = pd.read_stata(fichier, columns=colonnes, convert_categoricals=False)
df["poids"] = df["v005"] / 1e6                      # poids de sondage
```

Avant de modéliser. Lire le dictionnaire de l'enquête ; repérer les codes spéciaux (*ne sait pas*, *manquant*) ; vérifier les effectifs et les taux connus du rapport officiel de l'enquête ; puis seulement découper en apprentissage et test (chapitre 5).